OPTIMASI HYPERPARAMETER LONG SHORT-TERM MEMORY MENGGUNAKAN ALGORITMA OPTUNA PADA PREDIKSI HARGA BITCOIN

SKRIPSI

Diajukan sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer (S.Kom.)
pada Program Studi Teknik Informatika

Disusun Oleh:
ZAINI LEON MUSTHOFA KAMAL
NIM: 231240001455

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NAHDLATUL ULAMA JEPARA

2026

OPTIMASI HYPERPARAMETER LONG SHORT-TERM MEMORY MENGGUNAKAN ALGORITMA OPTUNA PADA PREDIKSI HARGA BITCOIN

SKRIPSI

Diajukan sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer (S.Kom.)
pada Program Studi Teknik Informatika

Disusun Oleh:
ZAINI LEON MUSTHOFA KAMAL
NIM: 231240001455

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NAHDLATUL ULAMA JEPARA

2026

SURAT PERNYATAAN KEASLIAN KARYA TULIS SKRIPSI

Yang bertanda tangan di bawah ini:

Nama	:	**Zaini Leon Musthofa Kamal**
NIM	:	**231240001455**
Program Studi	:	Teknik Informatika
Fakultas	:	Sains dan Teknologi, UNISNU Jepara

Menyatakan dengan sesungguhnya bahwa naskah Skripsi yang berjudul: "Optimasi Hyperparameter Long Short-Term Memory Menggunakan Algoritma Optuna Pada Prediksi Harga Bitcoin" adalah benar-benar hasil karya ilmiah mandiri saya sendiri, bukan merupakan karya tiruan, saduran, atau plagiasi dari karya orang lain, baik sebagian maupun seluruhnya. Sepanjang pengetahuan saya, tidak terdapat karya atau pendapat yang pernah ditulis atau diterbitkan oleh orang lain, kecuali yang secara tertulis dan formal disitasi dalam naskah ini serta dicantumkan dalam daftar pustaka sesuai dengan kaidah ilmiah.

Apabila di kemudian hari terbukti atau dapat dibuktikan bahwa skripsi ini merupakan hasil plagiasi, penjiplakan, atau rekayasa data yang melanggar kode etik akademik, maka saya bersedia menerima sanksi akademik yang seberat-beratnya sesuai dengan peraturan perundang-undangan yang berlaku dan Peraturan Rektor UNISNU Jepara, termasuk pencabutan gelar kesarjanaan yang telah saya peroleh.

Jepara, 20 Oktober 2026
Yang membuat pernyataan,

Meterai Rp10.000

Zaini Leon Musthofa Kamal
NIM: 231240001455

LEMBAR PERSETUJUAN PEMBIMBING

Naskah Skripsi dengan identitas sebagai berikut:

Nama Mahasiswa	:	**Zaini Leon Musthofa Kamal**
Nomor Induk Mahasiswa	:	**231240001455**
Program Studi	:	Teknik Informatika
Judul Skripsi	:	Optimasi Hyperparameter Long Short-Term Memory Menggunakan Algoritma Optuna Pada Prediksi Harga Bitcoin

Telah diperiksa dan disetujui oleh Dosen Pembimbing untuk diajukan dalam Ujian Sidang Skripsi (Munaqasyah) Program Studi Teknik Informatika Fakultas Sains dan Teknologi Universitas Islam Nahdlatul Ulama Jepara.

Jepara, 20 Oktober 2026
Menyetujui,
Dosen Pembimbing,

Teguh Tamrin, S.Kom., M.Kom.
NIDN. 0620127603 / NIY. 4 761220 17 235

LEMBAR PENGESAHAN SKRIPSI

Skripsi dengan judul "Optimasi Hyperparameter Long Short-Term Memory Menggunakan Algoritma Optuna Pada Prediksi Harga Bitcoin" yang disusun oleh Zaini Leon Musthofa Kamal (NIM: 231240001455) telah dipertahankan di hadapan Dewan Penguji Ujian Sidang Skripsi Program Studi Teknik Informatika Fakultas Sains dan Teknologi Universitas Islam Nahdlatul Ulama Jepara pada tanggal 20 Oktober 2026 dan dinyatakan LULUS serta diterima sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer (S.Kom.).

DEWAN PENGUJI:

Ketua Penguji	:	Teguh Tamrin, S.Kom., M.Kom. (.....)
Sekretaris Penguji	:	Gentur Wahyu Nyipto Wibowo, S.Kom., M.Kom. (.....)
Anggota Penguji	:	Danang Mahendra, S.Kom., M.Kom. (.....)

Mengesahkan,
Dekan Fakultas Sains dan Teknologi
Universitas Islam Nahdlatul Ulama Jepara

Dr. Arif Mustofa, S.T., M.Si.
NIY. 3 730617 13 124 / NIDN. 0617067302

HALAMAN PERSEMBAHAN

Alhamdulillahirabbil'alamin, dengan penuh rasa syukur ke hadirat Allah SWT atas segala limpahan rahmat, hidayah, dan kemudahan yang dianugerahkan-Nya, karya tulis skripsi yang sederhana ini saya persembahkan dengan segenap cinta, penghargaan, dan rasa hormat yang mendalam kepada:

- Kedua orang tua tercinta yang tiada henti memanjatkan doa tulus di setiap sujudnya, memberikan dukungan moril dan materil tanpa pamrih, serta menanamkan nilai-nilai kegigihan dan ketulusan dalam menuntut ilmu.
- Keluarga besar yang senantiasa menjadi sumber inspirasi, motivasi, dan kehangatan dalam setiap langkah perjuangan menempuh studi pendidikan sarjana.
- Dosen Pembimbing dan seluruh Bapak/Ibu Dosen Program Studi Teknik Informatika FST UNISNU Jepara yang telah ikhlas mentransfer ilmu pengetahuan, bimbingan, arahan metodologis, dan teladan integritas akademik yang tak ternilai.
- Rekan-rekan seperjuangan mahasiswa Program Studi Teknik Informatika FST UNISNU Jepara Angkatan 2023 atas kebersamaan, sinergi, diskusi intelektual, dan persahabatan yang senantiasa saling menguatkan.
- Almamater tercinta, Universitas Islam Nahdlatul Ulama (UNISNU) Jepara, sebagai kawah candradimuka yang menempa keilmuan teknologi informasi berlandaskan nilai-nilai Ahlussunnah wal Jama'ah.

HALAMAN MOTTO

"Barangsiapa bertakwa kepada Allah niscaya Dia akan mengadakan baginya jalan keluar, dan memberinya rezeki dari arah yang tiada disangka-sangkanya. Dan barangsiapa yang bertawakkal kepada Allah niscaya Allah akan mencukupkan (keperluan)nya."

(QS. At-Talaq: 2-3)

"Sesungguhnya Allah mencintai seorang hamba yang apabila mengerjakan suatu pekerjaan, ia melakukannya dengan itqan (profesional, tekun, dan tuntas)."

(HR. At-Thabrani dan Al-Baihaqi)

"Bukan kecerdasan semata yang menentukan keberhasilan penyelesaian suatu riset, melainkan ketekunan dalam menghadapi anomali data, kedisiplinan metode ilmiah, dan kerendahan hati untuk terus belajar memperbarui pemahaman."

(Zaini Leon Musthofa Kamal)

KATA PENGANTAR

Puji dan syukur senantiasa penulis panjatkan ke hadirat Allah SWT atas limpahan rahmat, taufiq, karunia, dan inayah-Nya, sehingga penulis dapat menyelesaikan penyusunan skripsi yang berjudul "Optimasi Hyperparameter Long Short-Term Memory Menggunakan Algoritma Optuna Pada Prediksi Harga Bitcoin" dengan baik dan lancar. Shalawat serta salam semoga senantiasa tercurahkan kepada junjungan kita Nabi Agung Muhammad SAW, keluarga, para sahabat, dan pengikutnya hingga akhir zaman.

Skripsi ini disusun sebagai salah satu syarat akademik guna menyelesaikan studi jenjang Strata 1 (S1) dan memperoleh gelar Sarjana Komputer (S.Kom.) pada Program Studi Teknik Informatika, Fakultas Sains dan Teknologi, Universitas Islam Nahdlatul Ulama (UNISNU) Jepara. Penulis menyadari sepenuhnya bahwa selesainya penulisan skripsi ini tidak terlepas dari bantuan, bimbingan, doa, dan motivasi dari berbagai pihak.

Oleh karena itu, dengan penuh kerendahan hati dan rasa hormat yang mendalam, penulis ingin menyampaikan ucapan terima kasih yang sebesar-besarnya kepada:

1. Prof. Dr. H. Abdul Djamil, M.A., selaku Rektor Universitas Islam Nahdlatul Ulama (UNISNU) Jepara, atas segala fasilitas dan kebijakan akademik yang mendukung kelancaran studi mahasiswa.
2. Dr. Arif Mustofa, S.T., M.Si., selaku Dekan Fakultas Sains dan Teknologi UNISNU Jepara, atas kepemimpinan, dedikasi, dan sarana prasarana yang disediakan selama masa perkuliahan.
3. Gentur Wahyu Nyipto Wibowo, S.Kom., M.Kom., selaku Ketua Program Studi Teknik Informatika FST UNISNU Jepara, atas pengarahan kurikulum, dorongan akademis, dan kemudahan proses administrasi tugas akhir.
4. Teguh Tamrin, S.Kom., M.Kom., selaku Dosen Pembimbing Skripsi, yang telah dengan penuh kesabaran, ketelitian, dan keikhlasan meluangkan waktu serta mencurahkan pemikiran dalam membimbing, mengarahkan, dan memberikan telaah kritis sejak awal pengajuan proposal hingga naskah skripsi ini terselesaikan

secara utuh dan teruji.
5. Seluruh Dewan Penguji Ujian Sidang Skripsi yang telah memberikan koreksi, evaluasi metodologis, dan masukan berharga demi penyempurnaan kualitas ilmiah naskah ini.
6. Seluruh Bapak dan Ibu Dosen serta staf akademik di lingkungan Program Studi Teknik Informatika dan Fakultas Sains dan Teknologi UNISNU Jepara yang telah membekali penulis dengan berbagai khazanah ilmu pengetahuan dan keteladanan budi pekerti luhur.
7. Kedua orang tua tercinta dan segenap keluarga besar yang senantiasa mengiringi setiap perjuangan penulis dengan doa yang tulus, limpahan kasih sayang yang tak bertepi, serta pengorbanan moril dan materiil yang tak terhingga nilainya.
8. Sahabat-sahabat dan rekan mahasiswa Program Studi Teknik Informatika UNISNU Jepara Angkatan 2023 atas kebersamaan, kekompakan, serta diskusi saintifik yang selalu membangun.

Penulis menyadari bahwa skripsi ini masih jauh dari kesempurnaan akibat keterbatasan pengalaman dan wawasan penulis. Meskipun demikian, penulis telah berusaha semaksimal mungkin mencurahkan kemampuan terbaik dalam menyelesaikan karya ini. Akhir kata, penulis berharap semoga skripsi ini dapat memberikan kontribusi nyata serta kemaslahatan bagi pengembangan ilmu pengetahuan dan teknologi, khususnya di bidang Artificial Intelligence, Deep Learning, dan rekayasa optimasi peramalan finansial.

Jepara, 20 Oktober 2026
Penulis,

Zaini Leon Musthofa Kamal
NIM: 231240001455

ABSTRAK

Zaini Leon Musthofa Kamal, 231240001455, Optimasi Hyperparameter Long Short-Term Memory Menggunakan Algoritma Optuna Pada Prediksi Harga Bitcoin, 2026.

Volatilitas ekstrem dan sifat non-stasioner pada harga penutupan Bitcoin menimbulkan tantangan dalam pemodelan deret waktu finansial. Arsitektur Long Short-Term Memory (LSTM) mampu menangkap ketergantungan temporal, tetapi kinerjanya sensitif terhadap hyperparameter dan aturan pelatihan. Penelitian ini merancang pipeline optimasi berbasis Tree-structured Parzen Estimator (TPE) melalui Optuna, lalu mengevaluasinya dengan matriks terkontrol E0 sampai E7. Data mencakup 2.192 harga penutupan harian BTC/USDT; 1.753 observasi in-sample dipakai untuk tuning dan 439 observasi holdout hanya untuk evaluasi akhir. Validasi memakai Time-Series Split berpurge, scaler per fold, lima seed, moving-block bootstrap, dan pembanding persistence. E7 menjalani 50 trial dan memilih lookback 25 hari, 112 unit, dropout 0,10, learning rate 0,00128, serta batch size 16. Evaluasi holdout menghasilkan RMSE USD 2.250,06, MAE USD 1.687,49, dan MAPE 1,72%. E7 mencatat MAE USD 1.687,49, lebih tinggi daripada persistence (USD 1.579,80), dengan CI selisih berpasangan yang seluruhnya di atas nol. Hasil ini secara statistik lebih buruk dan dilaporkan apa adanya; kontribusi penelitian diarahkan pada pipeline evaluasi serta bukti terkontrol tentang batas kemampuan LSTM. Model LSTM terbaik adalah E6 dengan MAE USD 1.667,26. Temuan ini menegaskan pentingnya baseline naif, pemisahan data tuning, dan pelaporan hasil negatif dalam riset peramalan aset kripto.

Kata Kunci: *Long Short-Term Memory, Optuna-TPE, Prediksi Harga Bitcoin, Optimasi Hyperparameter, Deret Waktu Finansial.*

ABSTRACT

Zaini Leon Musthofa Kamal, 231240001455, Hyperparameter Optimization of Long Short-Term Memory Using Optuna Algorithm in Bitcoin Price Prediction, 2026.

Extreme volatility and non-stationarity in Bitcoin closing prices pose substantial challenges for financial time-series modeling. Long Short-Term Memory (LSTM) networks can capture temporal dependencies, but their performance is sensitive to hyperparameters and training rules. This study builds a Tree-structured Parzen Estimator (TPE) pipeline in Optuna and evaluates it with a controlled E0-E7 matrix. The dataset contains 2.192 daily BTC/USDT closing prices; 1.753 in-sample observations were used for tuning and 439 holdout observations only for final evaluation. Validation used a purged Time-Series Split, per-fold scaling, five seeds, moving-block bootstrap, and a persistence benchmark. E7 ran 50 trials and selected a 25-day lookback, 112 units, dropout 0,10, learning rate 0,00128, and batch size 16. Holdout evaluation produced an RMSE of USD 2.250,06, MAE of USD 1.687,49, and MAPE of 1,72%. E7 achieved an MAE of USD 1.687,49, higher than persistence (USD 1.579,80), with a paired confidence interval entirely above zero. This result is statistically worse and is reported as such; the contribution is reframed as a controlled evaluation pipeline and evidence about the limits of LSTM. The best LSTM was E6 with an MAE of USD 1.667,26. These findings underline the importance of naive baselines, tuning-holdout separation, and transparent reporting of negative results in cryptocurrency forecasting research.

Keywords: *Long Short-Term Memory, Optuna-TPE, Bitcoin Price Forecasting, Hyperparameter Optimization, Financial Time-Series.*

DAFTAR ISI

HALAMAN SAMPUL LUAR i
HALAMAN SAMPUL DALAM ii
SURAT PERNYATAAN KEASLIAN iii
LEMBAR PERSETUJUAN PEMBIMBING v
LEMBAR PENGESAHAN SKRIPSI vi
HALAMAN PERSEMBAHAN vii
HALAMAN MOTTO viii
KATA PENGANTAR ix
ABSTRAK xi
ABSTRACT xii
DAFTAR ISI xiii
DAFTAR TABEL xv
DAFTAR GAMBAR xvi
DAFTAR LAMPIRAN xvii
BAB I PENDAHULUAN 1
A. Latar Belakang Masalah 1
B. Rumusan Masalah 4
C. Tujuan Penelitian 5
D. Manfaat Penelitian 5
E. Batasan Masalah 6
BAB II LANDASAN TEORI 7
A. Penelitian Terdahulu yang Relevan 7
B. Landasan Teori 14
1. Karakteristik Data Deret Waktu dan Volatilitas Pasar Bitcoin 14
2. Arsitektur Jaringan Saraf Tiruan Long Short-Term Memory (LSTM) 14
3. Ruang Pencarian Hyperparameter pada Arsitektur LSTM 15
4. Kerangka Kerja Optuna dan Algoritma Tree-structured Parzen Estimator (TPE) 16
5. Skema Validasi Deret Waktu (Time-Series Split / Walk-Forward) 17
6. Metrik Evaluasi Kinerja Peramalan Komputasi 18
C. Kerangka Berpikir Penelitian 19
D. Hipotesis Penelitian 20
BAB III METODE PENELITIAN 20
A. Jenis dan Pendekatan Penelitian 21
B. Waktu dan Tempat Penelitian 22
C. Populasi dan Sampel Penelitian 23
D. Instrumen Penelitian 24
E. Teknik Pengumpulan Data 27

F. Teknis Analisis Data 29
BAB IV HASIL PENELITIAN DAN PEMBAHASAN 36
A. Hasil Penelitian 36
1. Karakteristik Data dan Protokol Evaluasi 36
2. Baseline Persistence dan Baseline Naif 37
3. Model Kontrol Tier 1 dan Tier 2 37
4. Ablasi Loss dan Scheduler pada Parameter Tier 3 38
5. Hasil HPO Bersih Tier 3 (E7) 38
6. Perbandingan Statistik dan Verdict Ilmiah 39
7. Analisis Residual, Rezim, dan Arah 40
B. Pembahasan Hasil Penelitian 43
1. Mengapa Baseline Persistence Sulit Dikalahkan 43
2. Efek Hyperparameter Optuna: E1 versus E3 44
3. Efek Loss MAE dan Scheduler 44
4. Nilai Tambah HPO Penuh: E7 versus E6 45
5. Implikasi Teoritis dan Praktis 46
6. Keterbatasan Penelitian 46
7. Ringkasan Bab 47
BAB V PENUTUP 47
A. Simpulan 47
B. Saran 49
DAFTAR PUSTAKA 50
LAMPIRAN 54
Lampiran 1: Ringkasan Kode Program Pipeline Komputasi Python 54
Lampiran 2: Sampel Data Historis Transaksi Binance BTC/USDT 56
Lampiran 3: Log Riwayat Percobaan 50 Trial Optuna-TPE 58

DAFTAR TABEL

Tabel 2.1 Matriks Sintesis Penelitian Terdahulu dan Posisi Penelitian Ini 13
Tabel 3.1 Jadwal Pelaksanaan Kegiatan Penelitian 23
Tabel 3.2 Spesifikasi Instrumen Perangkat Lunak Penelitian 26
Tabel 3.3 Ruang Pencarian Hyperparameter LSTM pada Algoritma Optuna 30
Tabel 3.4 Matriks Eksperimen Terkontrol E0–E7 33
Tabel 3.5 Ringkasan Alur Prosedur Pelaksanaan Penelitian 35
Tabel 4.1 Statistik Deskriptif Harga Penutupan Bitcoin 36
Tabel 4.2 Kinerja Baseline Naif pada Holdout 37
Tabel 4.3 Hasil Ablasi Loss dan Scheduler 38
Tabel 4.4 Konfigurasi Final Model Usulan E7 38
Tabel 4.5 Perbandingan Kinerja Seluruh Model pada Holdout 40
Tabel 4.6 Perbandingan Berpasangan pada Tanggal yang Sama 40
Tabel 4.7 Kinerja E7 Menurut Rezim dan Volatilitas (Label Ex-Ante) 41

DAFTAR GAMBAR

Gambar 4.1 Kurva Konvergensi Nilai Validasi Optuna-TPE 39
Gambar 4.2 Perbandingan Harga Aktual dan Prediksi pada Holdout 42
Gambar 4.3 Diagram Batang Perbandingan Metrik 42
Gambar 4.4 Distribusi Galat Absolut Menurut Model 42
Gambar 4.5 Galat Menurut Rezim Pasar 43

DAFTAR LAMPIRAN

Lampiran 1: Ringkasan Kode Program Pipeline Komputasi Python (01 s.d. 08)..... 54
Lampiran 2: Sampel Data Historis Transaksi Binance BTC/USDT Periode 2020–202556
Lampiran 3: Log Riwayat Percobaan 50 Trial Optimasi Bayesian Optuna-TPE 58

BAB I
PENDAHULUAN

A. Latar Belakang Masalah

Perkembangan teknologi finansial berbasis komputasi terdesentralisasi telah menempatkan Bitcoin sebagai aset digital dengan volume transaksi dan kapitalisasi pasar terbesar di dunia. Karakteristik data deret waktu (time series) Bitcoin memperlihatkan tingkat volatilitas ekstrem serta non-stasioneritas yang sangat dinamis akibat dipengaruhi oleh likuiditas global dan sentimen pasar (Lim & Zohren, 2021; Aswadi & Ependi, 2025). Fluktuasi nilai tukar yang bergerak secara cepat dan tidak berpola linier tersebut menimbulkan tantangan komputasi yang rumit dalam bidang rekayasa kecerdasan buatan. Metode analisis statistik parametrik klasik seperti Autoregressive Integrated Moving Average (ARIMA) kerap mengalami degradasi performa karena ketidakmampuannya menangkap interaksi ketergantungan temporal jangka panjang yang kompleks. Keterbatasan pemodelan linier konvensional tersebut mendorong urgensi pemanfaatan paradigma pembelajaran mendalam (deep learning) yang adaptif terhadap dependensi sekuensial data.

Dalam domain pembelajaran mendalam untuk peramalan deret waktu, arsitektur Recurrent Neural Network (RNN) varian Long Short-Term Memory (LSTM) telah menjadi metode rujukan utama dalam memodelkan data sekuensial. Arsitektur LSTM yang diperkenalkan oleh Hochreiter & Schmidhuber (1997) dan dikaji lebih lanjut oleh Greff et al. (2017) dirancang secara spesifik untuk memecahkan permasalahan hilangnya gradien (vanishing gradient) yang melekat pada jaringan saraf berulang tradisional. Melalui integrasi tiga gerbang logika utama—input gate, forget gate, dan output gate—serta cell state internal, LSTM mampu mengatur retensi dan pembaruan informasi temporal secara selektif. Keunggulan struktural ini memungkinkan model mempertahankan memori historis penting melintasi rentang waktu yang panjang jauh melampaui algoritma machine learning standar (Ula et al., 2024). Kendati demikian, efektivitas

representasi fitur dan akurasi prediksi LSTM sangat bergantung pada ketepatan konfigurasi hyperparameter yang diterapkan.

Penentuan konfigurasi parameter optimal pada model jaringan saraf tiruan mendalam melibatkan ruang pencarian (search space) multidimensi yang bersifat non-konveks dan saling berinteraksi secara rumit. Parameter arsitektur seperti panjang jendela historis (lookback window), jumlah neuron tersembunyi, dropout rate, serta parameter pelatihan seperti learning rate dan batch size memiliki sensitivitas sangat tinggi terhadap performa konvergensi model (Goodfellow et al., 2016; Kervancı & Akay, 2023). Pada praktiknya, sejumlah kajian peramalan Bitcoin, seperti riset yang dipublikasikan oleh Khumaidi dkk. (2024) pada jurnal terakreditasi SINTA 2, masih mengandalkan penyesuaian parameter secara manual (trial-and-error) dengan kombinasi nilai yang sangat terbatas. Pendekatan manual ini terbukti tidak efisien, memerlukan intervensi subjektif, serta memiliki probabilitas tinggi terjebak pada titik optimum lokal (local minima) yang suboptimal. Kelemahan proses manual tersebut menuntut diterapkannya metode pencarian parameter otomatis yang terstruktur secara algoritmik.

Metode pencarian hyperparameter otomatis konvensional yang kerap digunakan pada penelitian informatika meliputi Grid Search dan Random Search. Studi komprehensif oleh Feurer & Hutter (2019) serta evaluasi empiris terkini pada instrumen aset kripto (Aldo dkk., 2026) mengungkapkan bahwa Grid Search menuntut biaya komputasi yang sangat mahal secara eksponensial seiring bertambahnya dimensi parameter yang diuji. Di sisi lain, meskipun Random Search menawarkan efisiensi waktu yang lebih baik, algoritma ini mengevaluasi parameter secara acak tanpa memanfaatkan riwayat informasi keberhasilan iterasi sebelumnya. Akibatnya, pada data deret waktu dengan tingkat derau (noise) tinggi, Random Search menghasilkan variansi performa yang tidak konsisten dan kerap berkinerja buruk (Aldo dkk., 2026). Oleh sebab itu, diperlukan algoritma optimasi cerdas berbasis probabilistik yang mampu memandu arah pencarian parameter secara terarah dan hemat sumber daya komputasi.

Kerangka kerja optimasi modern Optuna hadir memberikan solusi mutakhir terhadap inefisiensi eksplorasi ruang parameter pada model pembelajaran mendalam. Dikembangkan oleh Akiba et al. (2019), Optuna mengimplementasikan algoritma Bayesian Optimization berbasis Tree-structured Parzen Estimator (TPE) yang memodelkan fungsi objektif secara probabilistik (Bergstra et al., 2011). Pendekatan TPE mengelompokkan riwayat evaluasi konfigurasi parameter menjadi dua distribusi probabilitas kontinu guna menghitung kriteria Expected Improvement secara adaptif pada setiap langkah uji. Selain itu, fitur pemangkasan otomatis (Asynchronous MedianPruner) pada Optuna mampu menghentikan uji coba kandidat parameter yang berkinerja buruk secara dini sebelum proses pelatihan selesai (Akiba et al., 2019). Namun demikian, keandalan konfigurasi parameter yang ditemukan oleh Optuna sangat dipengaruhi oleh integritas skema validasi data.

Prosedur pembagian data statis (static train-test split) yang umum diterapkan pada penelitian deret waktu memiliki kelemahan metodologis yang berpotensi menghasilkan kesimpulan semu. Riset mutakhir oleh Wahyuddin dkk. (2025) menegaskan bahwa optimasi parameter deret waktu finansial yang hanya bertumpu pada potongan data statis menimbulkan bias estimasi serta kebocoran informasi masa depan (temporal data leakage). Pada instrumen Bitcoin yang kerap mengalami pergeseran rezim tren (regime shift), parameter yang tampak prima pada data latih statis sering kali mengalami degradasi drastis saat diuji pada fase pasar berikutnya (López de Prado, 2018). Untuk menjamin ketahanan model, penerapan skema validasi deret waktu berurutan (Time-Series Split / Walk-Forward) menjadi esensial guna mengevaluasi generalisasi model secara murni pada data out-of-sample (Tashman, 2000; Arlot & Celisse, 2010). Penggabungan algoritma Optuna-TPE dengan protokol validasi deret waktu menjadi celah riset utama yang sangat mendesak untuk dituntaskan.

Kesenjangan penelitian (research gap) ini ditempatkan pada rekayasa optimasi hyperparameter otomatis multi-dimensi model LSTM dengan protokol validasi deret waktu yang ketat dan bebas kebocoran data. Kajian terdahulu telah

meneliti optimasi LSTM pada aset digital alternatif (Aldo dkk., 2026) dan penyetelan manual pada Bitcoin (Khumaidi dkk., 2024), tetapi belum mengintegrasikan pencarian parameter terarah Optuna-TPE berbasis time-series split dengan baseline naif dan ablasi faktor pelatihan. Penelitian ini merancang ruang pencarian gabungan yang mencakup parameter arsitektur (lookback window, unit LSTM, dropout, jumlah layer) dan pelatihan (learning rate, batch size) secara terpadu. Pengujian empiris disusun sebagai matriks E0–E7 yang memisahkan efek HPO, loss, dan scheduler pada tanggal holdout yang sama. Evaluasi akurasi diukur melalui tiga metrik standar: RMSE, MAE, dan MAPE, dengan MAE sebagai metrik utama (Hyndman & Athanasopoulos, 2018; Willmott & Matsuura, 2005).

Implementasi kerangka kerja optimasi ini memberikan kontribusi nyata dalam memajukan metodologi rekayasa kecerdasan buatan pada peramalan deret waktu bervolatilitas tinggi. Pemanfaatan data historis harga penutupan Bitcoin (BTC/USDT) yang bersumber langsung dari bursa resmi Binance API (2024) menyediakan dasar empiris yang objektif dan transparan. Melalui optimasi terarah berbasis Optuna-TPE, proses penentuan arsitektur jaringan saraf tidak lagi didasarkan pada intuisi coba-coba manusia yang memakan waktu, melainkan berpijak pada pemodelan matematis probabilistik yang dapat dipertanggungjawabkan. Hasil pengujian akan menunjukkan apakah model teroptimasi benar-benar menurunkan galat dibandingkan baseline naif dan kontrol, bukan mengasumsikan keunggulan sejak awal; bila tidak, temuan negatif tersebut dilaporkan sebagai bagian dari kontribusi ilmiah. Berdasarkan seluruh latar belakang dan urgensi ilmiah tersebut, penelitian ini dilaksanakan dengan judul "Optimasi Hyperparameter Long Short-Term Memory Menggunakan Algoritma Optuna Pada Prediksi Harga Bitcoin".

B. Rumusan Masalah

Berdasarkan latar belakang masalah yang telah diuraikan, rumusan masalah dalam penelitian ini disusun secara berjenjang tanpa adanya duplikasi kata tanya sebagai berikut:

1. Bagaimana proses penentuan arsitektur dan konfigurasi hyperparameter optimal pada model Long Short-Term Memory (LSTM) menggunakan algoritma Optuna berbasis Tree-structured Parzen Estimator (TPE)?
2. Seberapa besar perbedaan nilai error (RMSE, MAE, dan MAPE) antara model LSTM teroptimasi Optuna dengan baseline persistence, model default, dan manual tuning, serta apakah perbedaan MAE tersebut didukung interval kepercayaan berpasangan?
3. Apakah konfigurasi hyperparameter hasil optimasi Optuna mampu mengalahkan baseline naif dan mempertahankan stabilitas akurasi ketika dievaluasi pada data holdout out-of-sample?

C. Tujuan Penelitian

Mengacu secara selaras kepada rumusan masalah yang diajukan, tujuan yang hendak dicapai melalui pelaksanaan penelitian ini adalah:

1. Menganalisis dan mengimplementasikan proses pencarian konfigurasi hyperparameter optimal pada model Long Short-Term Memory (LSTM) secara otomatis menggunakan kerangka kerja Optuna berbasis Tree-structured Parzen Estimator (TPE).
2. Mengukur dan membandingkan secara kuantitatif nilai error (Root Mean Square Error, Mean Absolute Error, dan Mean Absolute Percentage Error) model LSTM teroptimasi Optuna terhadap baseline persistence, model default, dan manual tuning, termasuk interval kepercayaan berpasangan.
3. Mengevaluasi ketahanan generalisasi model LSTM hasil optimasi Optuna pada data holdout out-of-sample dan menetapkan verdict ilmiah secara eksplisit, termasuk bila hasilnya tidak lebih baik daripada baseline naif.

D. Manfaat Penelitian

Hasil dari penelitian ini diharapkan dapat memberikan kontribusi nyata yang bermanfaat baik secara teoretis bagi perkembangan keilmuan informatika maupun secara praktis bagi para praktisi:

1. Manfaat Teoretis

Secara teoretis, penelitian ini memberikan sumbangan literatur ilmiah dalam domain rekayasa kecerdasan buatan (artificial intelligence) dan pembelajaran mendalam (deep learning), khususnya mengenai integrasi algoritma optimasi Bayesian berbasis Tree-structured Parzen Estimator (TPE) pada arsitektur Long Short-Term Memory (LSTM). Penelitian ini memperkaya khazanah metodologi peramalan data deret waktu bervolatilitas tinggi melalui pembuktian empiris bahwa proses optimasi otomatis dengan protokol validasi terstruktur mampu menghilangkan bias estimasi parameter model.

2. Manfaat Praktis

a. **Bagi Peneliti dan Akademisi:** Memberikan panduan kerangka kerja eksperimental yang teruji dalam menerapkan kerangka kerja Optuna untuk tuning model jaringan saraf berulang pada data deret waktu yang kompleks.

b. **Bagi Praktisi Teknologi dan Analis Komputasi:** Menyediakan rujukan arsitektur model peramalan otomatis yang efisien dalam penggunaan sumber daya komputasi melalui fitur early pruning, sehingga dapat diterapkan pada sistem analitik data skala besar.

c. **Bagi Program Studi Teknik Informatika UNISNU Jepara:** Menambah koleksi karya ilmiah tugas akhir yang berbobot, bereputasi tinggi, dan menerapkan metode kecerdasan buatan mutakhir yang relevan dengan perkembangan industri teknologi informasi global.

E. Batasan Masalah

Agar pelaksanaan penelitian ini berjalan secara terarah, terukur, dan fokus pada ruang lingkup keilmuan Teknik Informatika, maka batasan masalah ditetapkan sebagai berikut:

1. Data penelitian yang digunakan adalah data historis harga penutupan harian (daily closing price) cryptocurrency pasangan Bitcoin terhadap Tether (BTC/USDT) yang dihimpun dari platform Binance Public API.
2. Periode rentang waktu dataset mencakup rentang multi-tahun (2020 hingga 2024) guna merepresentasikan variasi kondisi pasar yang komprehensif, meliputi fase tren bullish, bearish, dan konsolidasi pasar.
3. Model pembelajaran mendalam (deep learning) yang diuji dan dioptimasi dibatasi secara khusus pada arsitektur Long Short-Term Memory (LSTM) berbasis input deret waktu univariat harga penutupan.
4. Algoritma optimasi hyperparameter yang diterapkan adalah Tree-structured Parzen Estimator (TPE) yang dijalankan melalui kerangka kerja Optuna dengan mekanisme pemangkasan otomatis Asynchronous MedianPruner.
5. Ruang pencarian (search space) hyperparameter yang dioptimasi difokuskan pada lima variabel komputasi utama, yaitu: panjang jendela historis (lookback window), jumlah unit neuron tersembunyi (hidden units), tingkat regulerisasi (dropout rate), laju pembelajaran (learning rate), dan ukuran batch pelatihan (batch size).
6. Skema evaluasi dan validasi data menggunakan metode Time-Series Split (Walk-Forward Validation) berurutan untuk menjamin pengujian bebas dari kebocoran data masa depan (temporal data leakage).
7. Metrik evaluasi performa akurasi dan kesalahan komputasi model dibatasi pada tiga indikator standar peramalan, yaitu Root Mean Square Error (RMSE), Mean Absolute Error (MAE), dan Mean Absolute Percentage Error (MAPE).

BAB II
LANDASAN TEORI

A. Penelitian Terdahulu yang Relevan

Penelitian mengenai peramalan deret waktu dan optimasi arsitektur deep learning telah berkembang pesat seiring dengan meningkatnya kebutuhan model prediktif pada instrumen bervolatilitas tinggi seperti cryptocurrency. Kajian terhadap literatur terdahulu memiliki peranan mendasar guna membedah kelebihan serta keterbatasan metodologi yang telah ada, sehingga posisi kebaruan (novelty) dan kontribusi penelitian ini dapat ditempatkan secara tegas dan dapat dipertanggungjawabkan (Creswell & Creswell, 2018). Penelitian ini berakar pada delapan kajian ilmiah utama yang menginvestigasi model Long Short-Term Memory (LSTM), teknik hyperparameter optimization (HPO), serta skema validasi deret waktu finansial. Rincian ulasan kritis terhadap masing-masing paper tersebut dijabarkan sebagai berikut:

1. Aldo dkk. (2026): Comparative Analysis of HPO Methods for LSTM

Kajian yang diterbitkan dalam Jurnal Teknik Informatika (JUTIF) oleh Aldo dkk. (2026) berjudul "Comparative Analysis of Hyperparameter Optimization Methods for LSTM in Cryptocurrency Price Prediction: An Application to TRX–USD" mengevaluasi enam teknik optimasi parameter (Grid Search, Random Search, Hyperopt, Optuna, Particle Swarm Optimization/PSO, dan Genetic Algorithm/GA) pada arsitektur LSTM menggunakan 2.096 data historis harian dari Binance. Hasil evaluasi empiris membuktikan bahwa metode metaheuristik dan Bayesian Optimization menghasilkan akurasi tertinggi, di mana GA dan Optuna mencapai nilai koefisien determinasi (R-squared) sebesar 0,8088 dengan error terendah, sementara Random Search terpuruk dengan R-squared hanya 0,28.

Kaitan dengan penelitian ini terletak pada pemilihan kerangka kerja Optuna sebagai algoritma pencarian hyperparameter utama yang telah terbukti secara empiris jauh lebih unggul dan efisien dibanding teknik acak maupun grid. Namun, keterbatasan kajian Aldo dkk. (2026) terletak pada pengujian yang hanya berfokus pada aset kripto alternatif (TRX/USD) dan hanya mengandalkan satu pembagian data statis (static train-test split). Penelitian ini mengatasi celah tersebut dengan memfokuskan pengujian pada aset utama Bitcoin (BTC/USDT) serta

mengintegrasikan skema Time-Series Split untuk menguji ketahanan model terhadap pergeseran rezim tren pasar.

2. Khumaidi, Kusmanto, dan Hikmah (ILKOM Jurnal Ilmiah, 2024)

Penelitian oleh Khumaidi dkk. (2024) yang dipublikasikan pada ILKOM Jurnal Ilmiah (SINTA 2) berjudul "Optimizing Bitcoin Price Predictions Using Long Short-Term Memory Algorithm: A Deep Learning Approach" menguji akurasi algoritma LSTM untuk memprediksi harga penutupan Bitcoin selama rentang waktu 3 tahun. Penyetelan hyperparameter dilakukan secara manual melalui tiga skenario variasi data latih (80%, 85%, 90%), ukuran batch (10 dan 20), serta 100 epoch. Hasil penelitian menyimpulkan bahwa konfigurasi data latih 85%, batch size 10, dan 100 epoch menghasilkan performa terbaik dengan tingkat akurasi rata-rata 93,69% dan tingkat kesalahan (error rate) terendah sebesar 6,31%.

Kajian Khumaidi dkk. (2024) menjadi rujukan krusial sekaligus berperan sebagai model pembanding Tier-2 Baseline (manual tuning) dalam penelitian ini. Kendati menunjukkan hasil yang baik, kelemahan mendasar penelitian tersebut adalah proses optimasi yang masih dilakukan secara coba-coba manual (trial-and-error) pada ruang parameter diskret yang sangat sempit. Penelitian ini menyempurnakan kelemahan tersebut dengan menggantikan proses coba-coba manual menggunakan optimasi cerdas berbasis algoritma Tree-structured Parzen Estimator (TPE) pada ruang pencarian kontinu berdimensi jamak.

3. Wahyuddin dkk. (2025): Sentiment Walk-Forward Validation

Studi komprehensif oleh Wahyuddin dkk. (2025) berjudul "Improved LSTM Hyperparameters Alongside Sentiment Walk-Forward" dalam jurnal bereputasi internasional (Scopus Q1) mengungkap fenomena kritis mengenai bias estimasi pada pemodelan deret waktu finansial. Penelitian tersebut membuktikan bahwa optimasi hyperparameter yang dijalankan pada potongan data statis menghasilkan kesimpulan semu akibat overfitting temporal. Dengan mengintegrasikan Bayesian Optimization bersama protokol validasi jendela bergerak (Walk-Forward Validation) melintasi 10 iterasi, studi tersebut berhasil

memangkas nilai RMSE rata-rata sebesar 24,3% dan meningkatkan stabilitas prediksi secara konsisten.

Penelitian Wahyuddin dkk. (2025) menjadi pijakan metodologis terpenting bagi penelitian ini dalam menerapkan skema validasi deret waktu yang ketat bebas kebocoran informasi masa depan (temporal data leakage). Celah penelitian yang disasar adalah bahwa studi Wahyuddin dkk. berfokus pada instrumen saham perbankan (BBRI) dengan volatilitas terkontrol. Penelitian ini membawa kebaruan metodologis tersebut ke dalam pasar Bitcoin yang memiliki volatilitas dan dinamika non-stasioneritas yang jauh lebih ekstrem, serta memperluas ruang pencarian ke arsitektur multi-layer LSTM.

4. Widad dkk. (2026): Comparative Analysis of LSTM and GRU Models with HPO

Artikel ilmiah oleh Widad dkk. (2026) pada jurnal Bit-Tech berjudul "Comparative Analysis of LSTM and GRU Models with Hyperparameter Optimization for Bitcoin Price Prediction" membandingkan efisiensi dan akurasi antara arsitektur Long Short-Term Memory (LSTM) dan Gated Recurrent Unit (GRU) pada data harga penutupan Bitcoin dari Yahoo Finance. Proses optimasi parameter dilakukan menggunakan metode Grid Search terstandardisasi. Temuan studi memperlihatkan adanya kompromi komputasi (accuracy-efficiency trade-off), di mana GRU unggul dalam kecepatan waktu pelatihan karena arsitekturnya yang lebih ringkas, sedangkan LSTM menunjukkan stabilitas metrik MAPE yang lebih baik pada peramalan rentang waktu panjang.

Kaitan kajian tersebut dengan penelitian ini adalah penegasan posisi LSTM sebagai model yang tangguh dalam mempertahankan dependensi temporal panjang. Celah riset yang ditinggalkan oleh Widad dkk. (2026) adalah penggunaan Grid Search yang menuntut biaya komputasi sangat mahal dan tidak realistis saat jumlah kombinasi parameter meningkat. Penelitian ini menjawab limitasi tersebut dengan menerapkan algoritma Optuna-TPE yang secara probabilistik memfokuskan pencarian pada area hyperparameter yang paling menjanjikan, sehingga memangkas waktu komputasi secara signifikan.

5. Fawzi dkk. (2025): Streamlit Implementation

Kajian terapan oleh Fawzi dkk. (2025) dalam Jurnal Teknik Informatika (JUTIF, SINTA 2) berjudul "Forecasting Bitcoin Price Prediction with Long Short-Term Memory Networks Implementation and Applications Using Streamlit" mengembangkan pipeline peramalan harga Bitcoin dari Yahoo Finance dan mengintegrasikannya ke dalam aplikasi web interaktif berbasis Streamlit. Model LSTM dievaluasi menggunakan metrik Mean Absolute Error (MAE sebesar 150,57) dan Root Mean Square Error (RMSE sebesar 231,90) untuk memvisualisasikan pergerakan harga historis dan masa depan secara langsung.

Kaitan penelitian Fawzi dkk. (2025) terhadap penelitian ini terletak pada standardisasi pipeline pemrosesan data deret waktu Bitcoin dan penggunaan metrik evaluasi formal. Namun, kelemahan utama dari penelitian tersebut adalah arsitektur LSTM yang digunakan masih berkonfigurasi bawaan (default/statis) tanpa adanya tahapan hyperparameter tuning sistematis. Penelitian ini mengisi celah tersebut dengan merekayasa proses optimasi hyperparameter otomatis multi-variabel dan menguji secara terkontrol apakah konfigurasi hasil pencarian benar-benar menurunkan galat pada data holdout.

6. Kervancı & Akay (2023): LSTM Hparam Optimization for Bitcoin

Penelitian oleh Kervancı & Akay (2023) yang diterbitkan pada Sakarya University Journal of Computer and Information Sciences berjudul "LSTM Hyperparameters Optimization with Hparam Parameters for Bitcoin Price Prediction" menginvestigasi pengaruh delapan hyperparameter arsitektur LSTM (go-backward, epoch, batch size, dropout rate, fungsi aktivasi, jenis optimizer, learning rate, dan jumlah neuron) terhadap error prediksi Bitcoin. Dengan memanfaatkan modul visualisasi koordinat paralel TensorBoard Hparam, studi tersebut menemukan bahwa optimizer Adam memberikan konvergensi Mean Square Error (MSE) terendah dan paling stabil dibandingkan SGD dan RMSprop pada data deret waktu.

Kajian Kervancı & Akay (2023) memberikan rujukan berharga bagi penelitian ini dalam menyusun batasan ruang pencarian (search space)

hyperparameter yang relevan pada model LSTM. Keterbatasan dari penelitian tersebut adalah modul Hparam hanya bertindak sebagai alat pemetaan kombinasi diskret pasif tanpa memiliki mekanisme pembelajaran konvergensi adaptif. Penelitian ini menggunakan algoritma Optuna-TPE dengan fungsi akuisisi Expected Improvement untuk memandu pencarian parameter secara adaptif, lalu menguji hasilnya pada protokol yang sama untuk seluruh model.

7. Ula, Ilhadi, dan Sidek (MATRIK, 2024): LSTM vs Random Forest

Artikel ilmiah pada jurnal terakreditasi SINTA 2 MATRIK (2024) berjudul "Comparing Long Short-Term Memory and Random Forest Accuracy for Bitcoin Price Forecasting" menguji perbandingan kinerja antara model deep learning LSTM dan algoritma ensemble machine learning Random Forest pada data historis penutupan Bitcoin. Hasil eksperimen empiris membuktikan bahwa arsitektur LSTM secara konsisten mengungguli Random Forest dengan menghasilkan nilai Mean Absolute Percentage Error (MAPE) yang jauh lebih kecil, membuktikan keandalan mekanisme gerbang berulang dalam menangkap pola autokorelasi deret waktu.

Kajian Ula dkk. (2024) memperkuat landasan teoretis penelitian ini bahwa LSTM merupakan salah satu arsitektur yang relevan untuk data deret waktu finansial yang sarat fluktuasi. Celah riset yang belum diselesaikan adalah bahwa model LSTM dalam studi tersebut masih menggunakan konfigurasi standar tanpa optimasi hyperparameter. Penelitian ini menguji secara terkontrol apakah optimasi terarah berbasis algoritma Optuna menurunkan galat absolut dibandingkan konfigurasi default dan baseline naif pada holdout yang sama.

8. Akiba et al. (2019) dan Bergstra et al. (2011): Optuna & TPE

Kajian seminal oleh Akiba et al. (2019) pada ACM SIGKDD berjudul "Optuna: A Next-Generation Hyperparameter Optimization Framework" memperkenalkan arsitektur Define-by-Run dan strategi pemangkasan otomatis (Asynchronous Successive Halving / MedianPruner). Algoritma pencarian probabilistik yang digunakan berpijak pada fondasi matematis Tree-structured Parzen Estimator (TPE) yang dikembangkan oleh Bergstra et al. (2011) pada

konferensi NIPS, yang memodelkan distribusi probabilitas konfigurasi hyperparameter berdasarkan riwayat evaluasi fungsi loss melalui aturan Bayes.

Paper Akiba et al. (2019) dan Bergstra et al. (2011) menjadi landasan teoretis dan algoritmik utama bagi instrumen optimasi dalam penelitian ini. Kontribusi kebaruan penelitian ini adalah mengimplementasikan algoritma Optuna-TPE pada model LSTM untuk data deret waktu Bitcoin dengan mengintegrasikan mekanisme pemangkasan dini (early pruning) dan skema validasi deret waktu (Time-Series Split), lalu mengevaluasi secara terbuka apakah model yang dihasilkan lebih akurat dan efisien secara komputasi.

Tabel 2.1 Matriks Sintesis Penelitian Terdahulu dan Posisi Penelitian Ini

No	Peneliti & Tahun	Metode & Model	Dataset & Objek	Temuan Utama	Celah Riset & Posisi Penelitian Ini
1	Aldo dkk. (2026)	LSTM + 6 HPO (Grid, Random, Optuna, Hyperopt, PSO, GA)	TRX/USD Binance (2.096 data harian)	Optuna & GA mencapai akurasi tertinggi (R2 = 0,8088); Random Search terburuk.	Celah: Hanya uji koin alternatif dan static split. Posisi: Menguji Bitcoin dengan Time-Series Split.
2	Khumaidi dkk. (ILKOM, 2024)	LSTM + Penyetelan Manual (Trial-and-Error)	Bitcoin Closing Price (3 tahun data)	Kombinasi batch 10, split 85%, epoch 100 hasilkan akurasi 93,69% dan error 6,31%.	Celah: Pencarian manual diskret rawan local minima. Posisi: Dijadikan Tier-2 Baseline pembanding.
3	Wahyuddin dkk. (2025)	LSTM + Bayesian Optimization + Walk-Forward	Data Saham & Indikator Finansial	Static split picu biased estimation error; walk-forward pangkas RMSE 24,3%.	Celah: Terbatas pada saham perbankan. Posisi: Menerapkan walk-forward pada Bitcoin.
4	Widad dkk. (2026)	Komparasi LSTM vs GRU + Grid Search	Bitcoin Closing Price (Yahoo Finance)	GRU lebih cepat dalam komputasi, namun LSTM lebih stabil dalam MAPE.	Celah: Grid Search boros komputasi eksponensial. Posisi: Mengganti Grid Search dengan Optuna-TPE.
5	Fawzi dkk. (2025)	LSTM Default + Web App Streamlit	Bitcoin Closing Price (Yahoo Finance)	Berhasil visualisasi prediksi interaktif dengan MAE 150,57 dan RMSE 231,90.	Celah: Parameter model statis tanpa optimasi. Posisi: Melakukan optimasi otomatis multi-variabel.
6	Kervancı & Akay (2023)	LSTM + TensorBoard HParam	Data Bitcoin (8 parameter uji)	Optimizer Adam paling stabil dan menghasilkan MSE terendah.	Celah: Hparam hanya pemetaan pasif tanpa konvergensi. Posisi: Optimasi probabilistik terarah via TPE.
7	Ula dkk. (MATRIK, 2024)	Komparasi LSTM vs Random Forest	Data Deret Waktu Bitcoin	LSTM terbukti lebih unggul dibanding Random Forest pada data temporal.	Celah: Model LSTM tidak dioptimasi (default). Posisi: Mengoptimalkan

					parameter LSTM secara penuh.
8	Akiba et al. (2019) & Bergstra (2011)	Framework Optuna & Algoritma TPE	Algoritma HPO & Benchmark ML	Define-by-Run dan TPE memangkas waktu komputasi via Asynchronous MedianPruner.	Celah: Paper fondasi algoritma umum. Posisi: Instrumen optimasi utama model LSTM Bitcoin.
9	**Penelitian Ini (Zaini, 2026)**	**LSTM Teroptimasi Optuna-TPE + Time-Series Split**	**Data Deret Waktu Harian BTC/USDT (Binance API)**	**Menguji E0–E7 secara terkontrol; E7 tidak lebih baik daripada persistence pada MAE, dan E6 menjadi LSTM terbaik.**	**Posisi: pipeline evaluasi terkontrol dengan baseline naif, CI berpasangan, dan pelaporan hasil negatif.**

B. Landasan Teori

1. Karakteristik Data Deret Waktu dan Volatilitas Pasar Bitcoin

Data deret waktu (time series) didefinisikan sebagai sekumpulan observasi terindeks waktu yang dihasilkan melalui proses pengukuran berulang pada interval waktu diskret yang teratur (Hyndman & Athanasopoulos, 2018). Dalam ekosistem aset digital, data harga historis Bitcoin (BTC/USDT) membentuk struktur deret waktu dengan derajat non-stasioneritas yang sangat tinggi, di mana parameter statistik seperti rata-rata (mean) dan variansi tidak konstan sepanjang waktu (Lim & Zohren, 2021). Pasar mata uang kripto beroperasi tanpa jeda selama 24 jam sehari secara global, menjadikan pergerakan harga penutupan harian sangat sensitif terhadap perubahan likuiditas, sentimen publik, serta pergeseran tren pasar (regime shift) yang tidak berpola linier (Aswadi & Ependi, 2025).

2. Arsitektur Jaringan Saraf Tiruan Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) merupakan arsitektur mutakhir dari Recurrent Neural Network (RNN) yang dirancang secara khusus oleh Hochreiter & Schmidhuber (1997) guna memecahkan masalah hilangnya gradien (vanishing gradient) dan ledakan gradien (exploding gradient) pada data sekuensial panjang. Pada RNN konvensional, perkalian matriks bobot berulang melintasi langkah waktu menyebabkan sinyal kesalahan melemah secara eksponensial saat ditransmisikan kembali melalui waktu (backpropagation through time). LSTM

mengatasi kendala tersebut dengan memperkenalkan cell state internal (C_t) sebagai jalur transmisi memori linear yang diregulasi oleh tiga gerbang logika utama: forget gate (f_t), input gate (i_t), dan output gate (o_t) (Greff et al., 2017).

Mekanisme transmisi data dan pembaruan keadaan memori internal sel LSTM pada langkah waktu t dengan vektor masukan x_t dan vektor keadaan tersembunyi sebelumnya h_{t-1} diformulasikan secara matematis melalui Persamaan (2.1) sampai dengan Persamaan (2.6) sebagai berikut (Hochreiter & Schmidhuber, 1997; Goodfellow et al., 2016):

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \tag{2.1}$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \tag{2.2}$$

$$\tilde{C}_t = tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \tag{2.3}$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \tag{2.4}$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \tag{2.5}$$

$$h_t = o_t \odot tanh(C_t) \tag{2.6}$$

Pada rangkaian persamaan di atas, simbol W dan b masing-masing menyatakan matriks bobot dan vektor bias yang dipelajari selama pelatihan, σ menyatakan fungsi aktivasi non-linier sigmoid, dan simbol $\odot$ menyatakan operasi perkalian elemen-per-elemen (Hadamard product). Forget gate (f_t) menentukan fraksi memori lama C_{t-1} yang harus dilupakan, input gate (i_t) bersama kandidat pembaruan $\tilde{C}_t$ mengatur informasi baru yang diserap ke dalam keadaan sel C_t, dan output gate (o_t) mengontrol pembentukan vektor keadaan tersembunyi h_t yang diteruskan sebagai keluaran prediksi pada langkah waktu t (Greff et al., 2017; Goodfellow et al., 2016).

3. Ruang Pencarian Hyperparameter pada Arsitektur LSTM

Hyperparameter merupakan parameter konfigurasi arsitektur dan algoritma yang nilainya ditetapkan secara eksternal sebelum proses pembelajaran model dimulai, berbeda dengan parameter bobot yang dipelajari secara internal dari data latih (Goodfellow et al., 2016). Kinerja generalisasi model LSTM sangat sensitif

terhadap kombinasi lima hyperparameter utama: panjang jendela historis (lookback window), jumlah unit neuron tersembunyi (hidden units), tingkat regulerisasi (dropout rate), laju pembelajaran (learning rate), dan ukuran batch pelatihan (batch size) (Feurer & Hutter, 2019; Kervancı & Akay, 2023). Panjang lookback window menentukan seberapa jauh horizon data masa lalu yang dianalisis oleh sel memori untuk menghasilkan proyeksi harga satu langkah ke depan (Boongasame & Songram, 2023).

Sementara itu, jumlah unit neuron pada hidden layer mengatur kapasitas representasi fitur jaringan, di mana kapasitas yang terlalu kecil memicu underfitting sedangkan unit yang berlebih menyebabkan overfitting dan pemborosan komputasi. Guna mencegah terjadinya fenomena overfitting pada data deret waktu, teknik regularisasi Dropout diterapkan dengan mematikan sebagian koneksi neuron secara acak dengan probabilitas p selama proses iterasi pelatihan (Srivastava et al., 2014). Adapun laju pembelajaran (learning rate) dan ukuran batch (batch size) mengendalikan kestabilan serta kecepatan konvergensi algoritma optimizer Adam dalam memperbarui bobot gradien (Kingma & Ba, 2014). Interaksi non-linier antara variabel-variabel ini membentuk ruang pencarian (search space) multidimensi yang menuntut metode optimasi cerdas otomatis.

4. Kerangka Kerja Optuna dan Algoritma Tree-structured Parzen Estimator (TPE)

Optuna merupakan kerangka kerja optimasi hyperparameter generasi baru berbasis paradigma Define-by-Run yang dirancang oleh Akiba et al. (2019) guna mengatasi inefisiensi ruang pencarian pada model deep learning. Berbeda dari kerangka kerja lama yang mengharuskan definisi ruang parameter statis secara kaku, Optuna memungkinkan pembentukan ruang parameter secara dinamis menggunakan struktur kontrol Python standar. Algoritma pencarian probabilistik utama yang diimplementasikan Optuna adalah Tree-structured Parzen Estimator (TPE), yang tergolong dalam kelas Sequential Model-Based Optimization (SMBO) berbasis inferensi Bayesian (Bergstra et al., 2011).

Alih-alih memodelkan probabilitas $P(y|x)$ secara langsung menggunakan Gaussian Process yang membutuhkan komputasi kubik $O(N^3)$, algoritma TPE memodelkan probabilitas kondisional parameter $P(x|y)$ dengan memisahkan riwayat evaluasi konfigurasi menjadi dua fungsi densitas probabilitas terpisah berdasarkan batas kuantil γ (Bergstra et al., 2011):

$$P(x|y) = \begin{cases} \ell(x) & apabila\ y < y* \\ g(x) & apabila\ y \geq y* \end{cases} \tag{2.7}$$

Pada Persamaan (2.7), $\ell(x)$ merepresentasikan densitas probabilitas dari konfigurasi parameter yang menghasilkan nilai loss unggul (di bawah ambang y^*), sedangkan $g(x)$ merepresentasikan densitas dari konfigurasi berkinerja buruk. Kandidat konfigurasi hyperparameter berikutnya dipilih dengan memaksimalkan kriteria Expected Improvement (EI), yang secara matematis setara dengan memaksimalkan rasio densitas $\ell(x)/g(x)$ melalui Persamaan (2.8) (Bergstra et al., 2011):

$$\begin{aligned} EI_{y^*}(x) &= \frac{\gamma \cdot y* \cdot \ell(x) - \ell(x) \cdot \int P(y)dy}{\gamma \cdot \ell(x) + (1-\gamma) \cdot g(x)} \\ &\propto \left(\gamma + \frac{g(x)}{\ell(x)} \cdot (1-\gamma)\right)^{-1} \end{aligned} \tag{2.8}$$

Mekanisme rasio densitas ini menjamin bahwa Optuna secara aktif mengeksplorasi kandidat parameter yang memiliki probabilitas tinggi menghasilkan error rendah (meningkatkan $\ell(x)$) sekaligus menjauhi kandidat yang berulang kali gagal (menekan $g(x)$). Di samping itu, keunggulan komputasi Optuna diperkuat oleh algoritma pemangkasan Asynchronous MedianPruner, yang membandingkan nilai loss parsial model pada langkah epoch berjalan terhadap nilai median riwayat uji coba terdahulu dan secara otomatis memutus uji coba yang tidak menjanjikan sebelum mencapai epoch maksimum (Akiba et al., 2019; Optuna Development Team, 2024).

5. Skema Validasi Deret Waktu (Time-Series Split / Walk-Forward)

Penerapan validasi silang konvensional seperti k-Fold Cross-Validation yang mengacak urutan observasi merupakan kesalahan fatal pada data deret waktu

karena merusak struktur dependensi autokorelasi temporal dan memicu kebocoran informasi masa depan ke masa lalu (temporal data leakage) (Arlot & Celisse, 2010; López de Prado, 2018). Untuk mencegah kebocoran data tersebut, prosedur validasi baku yang wajib digunakan adalah Time-Series Split (dikenal pula sebagai Walk-Forward Validation atau Expanding Window) (Tashman, 2000; Wahyuddin dkk., 2025). Pada skema ini, pelatihan model dibatasi hanya pada jendela historis $t \in [1, T]$, sedangkan evaluasi performa dilakukan secara murni pada jendela waktu sesudahnya $t \in [T+1, T+k]$ tanpa pernah menyentuh data masa depan dalam proses pelatihan.

6. Metrik Evaluasi Kinerja Peramalan Komputasi

Evaluasi kinerja model peramalan deret waktu dilakukan secara kuantitatif melalui pengukuran selisih deviasi antara nilai aktual penutupan Bitcoin (y_t) dan nilai hasil prediksi model ($\hat{y}_t$) untuk total n observasi pada periode pengujian out-of-sample. Tiga metrik standar peramalan komputasi yang digunakan dalam penelitian ini adalah Root Mean Square Error (RMSE), Mean Absolute Error (MAE), dan Mean Absolute Percentage Error (MAPE), yang diformulasikan secara formal melalui Persamaan (2.9) hingga Persamaan (2.11) sebagai berikut (Hyndman & Athanasopoulos, 2018; Willmott & Matsuura, 2005):

$$RMSE = \sqrt{\frac{1}{n}\sum_{t=1}^{n}(y_t - \hat{y}_t)^2} \tag{2.9}$$

$$MAE = \frac{1}{n}\sum_{t=1}^{n}|y_t - \hat{y}_t| \tag{2.10}$$

$$MAPE = \frac{100\%}{n}\sum_{t=1}^{n}\left|\frac{y_t - \hat{y}_t}{y_t}\right| \tag{2.11}$$

Metrik RMSE memberikan penalti kuadratik yang lebih berat terhadap deviasi kesalahan bernilai besar, sehingga sangat sensitif dalam mendeteksi adanya kegagalan peramalan ekstrem (outlier errors). Sebaliknya, metrik MAE

mengukur nilai absolut kesalahan secara proporsional dan tidak memperbesar bobot outlier, mencerminkan deviasi magnitudo harga riil secara stabil (Willmott & Matsuura, 2005). Sementara itu, metrik MAPE menormalisasi kesalahan ke dalam skala persentase relatif terhadap harga aktual, memberikan kemudahan interpretasi akurasi ketika diuji pada periode harga Bitcoin yang mengalami eskalasi nilai yang sangat masif (Hyndman & Athanasopoulos, 2018).

C. Kerangka Berpikir Penelitian

Kerangka berpikir penelitian ini dibangun berdasarkan penalaran komputasi terstruktur guna memecahkan kesenjangan antara karakteristik non-stasioneritas data Bitcoin dengan keterbatasan metode peramalan yang telah ada sebelumnya. Alur logis keterkaitan antarvariabel dan tahapan metodologis penyelesaian masalah dirumuskan secara sistematis sebagai berikut:

1. **Identifikasi Masalah (Problem Identification):** Data deret waktu harga Bitcoin memiliki non-stasioneritas ekstrem dan pergeseran rezim tren pasar. Penyetelan parameter model deep learning LSTM selama ini masih mengandalkan penyesuaian manual (trial-and-error) yang terbatas dan rawan local minima (Khumaidi dkk., 2024), sedangkan Grid Search menuntut komputasi eksponensial yang tidak terukur (Widad dkk., 2026). Selain itu, evaluasi berbasis static split menimbulkan biased estimation error (Wahyuddin dkk., 2025).
2. **Intervensi Metodologis (Methodological Intervention):** Menerapkan kerangka kerja optimasi otomatis Optuna berbasis algoritma probabilistik Tree-structured Parzen Estimator (TPE) untuk mengeksplorasi ruang pencarian hyperparameter arsitektur dan pelatihan LSTM secara efisien, dipadukan dengan mekanisme pemangkasan Asynchronous MedianPruner.
3. **Protokol Validasi Bebas Kebocoran (Data Validation Scheme):** Mengintegrasikan proses optimasi dan evaluasi model dengan skema Time-Series Split (Walk-Forward Validation) untuk menjamin parameter yang

ditemukan teruji secara murni pada data out-of-sample lintas periode pasar tanpa kebocoran data masa depan (temporal data leakage).

4. **Pengujian Empiris Terkontrol (Matriks E0–E7):** Membandingkan persistence (E0), Tier 1 default (E1), replikasi manual Khumaidi dkk. (E2), ablasi loss/scheduler (E3–E6), dan HPO penuh (E7) pada tanggal holdout yang sama menggunakan RMSE, MAE, dan MAPE, dengan MAE sebagai metrik utama dan interval kepercayaan berpasangan.
5. **Kontribusi Ilmiah (Expected Scientific Contribution):** Konfigurasi hyperparameter yang dapat diaudit, bukti terkontrol tentang ada atau tidaknya nilai tambah HPO, serta pipeline evaluasi bebas kebocoran. Bila model tidak mengalahkan persistence, temuan negatif dilaporkan sebagai kontribusi, bukan ditutupi oleh klaim keunggulan.

D. Hipotesis Penelitian

Berdasarkan landasan teori, kajian penelitian terdahulu yang komprehensif, serta kerangka berpikir penelitian, maka hipotesis penelitian dirumuskan secara terarah guna menjawab rumusan masalah sebagai berikut:

H1: Algoritma Optuna berbasis Tree-structured Parzen Estimator (TPE) mampu mengidentifikasi konfigurasi hyperparameter optimal model Long Short-Term Memory (LSTM) secara konvergen dan terarah pada ruang pencarian multidimensi.

H2: Model LSTM yang dioptimasi menggunakan Optuna-TPE menghasilkan MAE lebih rendah daripada baseline persistence dan kontrol default, dengan selisih berpasangan yang interval kepercayaan 95%-nya tidak melewati nol.

H3: Konfigurasi hyperparameter model LSTM hasil optimasi Optuna mampu mempertahankan stabilitas akurasi prediksi ketika dievaluasi pada data holdout out-of-sample; bila H2 ditolak, H3 dilaporkan sebagai evaluasi stabilitas tanpa klaim keunggulan.

BAB III
METODE PENELITIAN

A. Jenis dan Pendekatan Penelitian

Penelitian ini secara fundamental mengadopsi jenis penelitian kuantitatif dengan pendekatan eksperimental komputasi (computational experimental research) pada domain kecerdasan buatan dan rekayasa pembelajaran mesin. Pemilihan pendekatan kuantitatif didasari oleh kebutuhan untuk mengukur, menganalisis, serta menguji secara empiris ada atau tidaknya perbedaan kinerja peramalan harga Bitcoin sebelum dan sesudah intervensi optimasi hyperparameter dijalankan. Pendekatan ini memposisikan model Long Short-Term Memory (LSTM) sebagai subjek perlakuan komputasional terarah, di mana konfigurasi hyperparameter dimanipulasi secara adaptif melalui algoritma Optuna berbasis Tree-structured Parzen Estimator guna meminimalkan fungsi kerugian validasi (Akiba et al., 2019; Creswell & Creswell, 2018). Seluruh parameter keluaran diukur secara objektif melalui metrik evaluasi numerik terstandar, sehingga temuan yang dihasilkan memiliki landasan validitas internal yang sangat kuat serta terbebas dari bias penafsiran kualitatif subjektif (Feurer & Hutter, 2019).

Rancangan eksperimen kuantitatif ini disusun sebagai matriks terkontrol E0 sampai E7 agar perbandingan performa bersifat adil dan dapat diaudit. Ketiadaan baseline naif pada berbagai penelitian peramalan sering memicu klaim keunggulan model yang semu akibat pemilihan pembanding yang terlalu lemah. Matriks ini menempatkan persistence (E0) sebagai ambang minimum, Tier 1 (E1) dan Tier 2 (E2) sebagai kontrol, E3 sampai E6 sebagai ablasi faktorial loss dan scheduler, serta E7 sebagai model usulan yang menjalani HPO penuh dengan Optuna-TPE (Bouthillier et al., 2021). Dengan desain ini, efek hyperparameter, fungsi kerugian, scheduler, dan HPO dapat dipisahkan, bukan tercampur dalam satu perbandingan. Matriks tersebut memungkinkan penelitian menilai apakah optimasi probabilistik terarah benar-benar melampaui baseline dan kontrol, bukan hanya melampaui konfigurasi yang lemah (Makridakis et al., 2018).

Pendekatan eksperimen komputasional ini diimplementasikan sepenuhnya secara in-silico pada lingkungan perangkat lunak terisolasi tanpa melibatkan

subjek manusia maupun intervensi laboratorium fisik basah. Karakteristik data deret waktu finansial yang bergerak sangat cepat dan memiliki dinamika non-linier menuntut suatu lingkungan eksperimen yang sepenuhnya deterministik, terkendali, dan dapat direplikasi secara identik oleh peneliti lain. Seluruh siklus hidup penelitian—mulai dari akuisisi data historis, rekayasa fitur sekuensial, pemisahan data temporal bebas kebocoran, pencarian hyperparameter, hingga pengujian out-of-sample—dijalankan melalui skrip program otomatis (López de Prado, 2018). Paradigma komputasi modern ini telah diakui secara luas dalam disiplin ilmu informatika dan sains data sebagai metodologi baku yang sah untuk menghasilkan penemuan ilmiah yang kredibel dan memiliki reprodusibilitas tinggi (Goodfellow et al., 2016; Lim & Zohren, 2021).

B. Waktu dan Tempat Penelitian

Penelitian skripsi ini dilaksanakan secara intensif dalam rentang waktu selama lima bulan, terhitung sejak bulan Oktober 2026 sampai dengan bulan Februari 2027. Alokasi waktu tersebut disusun secara sekuensial dan terstruktur ke dalam lima tahapan kerja utama guna mengantisipasi beban komputasi yang tinggi pada fase optimasi hyperparameter dengan validasi silang temporal. Tahapan kerja tersebut meliputi studi kepustakaan mendalam dan penyusunan proposal (Oktober–November 2026), akuisisi data serta prapemrosesan (November–Desember 2026), implementasi model dan optimasi Optuna-TPE (Desember 2026–Januari 2027), evaluasi benchmark bertingkat (Januari 2027), hingga analisis komparatif serta penyusunan laporan skripsi lengkap (Januari–Februari 2027). Seluruh jadwal dirancang selaras dengan pedoman kalender akademik Fakultas Sains dan Teknologi UNISNU Jepara (UNISNU, 2023; Creswell & Creswell, 2018).

Pelaksanaan operasional penelitian ini bertempat di Jepara, Jawa Tengah, dengan memanfaatkan sistem komputasi stasiun kerja mandiri yang terhubung langsung ke jaringan internet berkecepatan tinggi. Karakteristik penelitian informatika berbasis pemodelan kecerdasan buatan tidak menuntut kehadiran fisik di lokasi geografis tertentu atau laboratorium lapangan basah konvensional.

Peneliti mengakses repositori data pasar keuangan global secara daring melalui antarmuka pertukaran aset kripto Binance, sementara seluruh tahapan pelatihan jaringan saraf dieksekusi secara lokal pada stasiun kerja komputasi pribadi. Fleksibilitas spasial ini memungkinkan eksperimen komputasi dijalankan secara kontinu dan terkontrol penuh tanpa terpengaruh hambatan fisik lokasi, sejalan dengan prinsip riset sains data dan rekayasa perangkat lunak modern berskala internasional (López de Prado, 2018; Tashman, 2000).

Tabel 3.1 Jadwal Pelaksanaan Kegiatan Penelitian

No	Tahapan Kegiatan Penelitian	Okt 2026	Nov 2026	Des 2026	Jan 2027	Feb 2027
1	Studi Literatur & Penyusunan Proposal Skripsi	✓	✓			
2	Akuisisi Data Binance API & Prapemrosesan		✓	✓		
3	Implementasi LSTM & Optimasi Optuna-TPE			✓	✓	
4	Evaluasi Matriks E0–E7 & Analisis Hasil				✓	✓
5	Penyusunan Naskah Lengkap & Sidang Skripsi					✓

C. Populasi dan Sampel Penelitian

Populasi sasaran dalam penelitian kuantitatif ini adalah seluruh catatan riwayat transaksi harga perdagangan pasar spot untuk pasangan mata uang kripto Bitcoin terhadap Tether (BTC/USDT) yang terdokumentasi pada platform bursa aset digital Binance. Berbeda dari pasar modal konvensional yang memiliki jam operasional terbatas dan libur akhir pekan, pasar mata uang kripto bergerak aktif selama 24 jam tanpa henti sepanjang tahun sehingga menghasilkan struktur data deret waktu berdensitas sangat tinggi. Binance dipilih sebagai penyedia populasi data utama karena menempati peringkat teratas dunia dalam hal volume perdagangan likuid harian dan kedalaman pasar spot (Binance Developer API, 2024). Ukuran likuiditas yang sangat masif ini menjamin bahwa fluktuasi harga yang tercatat merefleksikan harga kesepakatan wajar global yang bebas dari distorsi manipulasi likuiditas bursa lokal (Gu et al., 2020).

Penentuan sampel penelitian dilakukan secara sistematis menggunakan teknik purposive sampling dengan menetapkan sekumpulan kriteria inklusi berbasis kebutuhan arsitektur pemodelan pembelajaran mendalam. Pengambilan data deret waktu finansial tanpa kriteria yang ketat berisiko tinggi menyertakan celah data hilang atau gangguan instrumen yang dapat mendistorsi proses pembentukan jendela sekuensial pada model LSTM. Kriteria inklusi yang ditetapkan mencakup: data berbentuk candlestick harian (daily OHLCV) lengkap, rentang waktu historis mencakup minimal enam tahun kalender perdagangan, serta bebas dari kegagalan pencatatan sistem. Berdasarkan penerapan kriteria tersebut, sampel penelitian yang diperoleh mencakup data harian dari tanggal 1 Januari 2020 hingga 31 Desember 2025 dengan total 2.192 baris observasi berurutan (Hyndman & Athanasopoulos, 2018; Arlot & Celisse, 2010).

Penetapan rentang waktu sampel selama enam tahun penuh secara sengaja dirancang untuk mencakup seluruh keragaman rezim pasar finansial utama kripto, mencakup tren naik tajam (bullish), tren penurunan tajam (bearish), serta fase konsolidasi menyamping (sideways). Kelemahan mendasar dari banyak model kecerdasan buatan terdahulu adalah runtuhnya akurasi saat diuji di luar periode latihan karena model hanya dilatih pada satu kondisi pasar tunggal. Periode pengamatan 2020–2025 merangkum momen peristiwa Bitcoin Halving ketiga pada Mei 2020, pencapaian rekor tertinggi harga historis pada November 2021, penurunan ekstrem pasar beruang pada 2022, hingga periode konsolidasi institusional 2023–2025 (Wahyuddin dkk., 2025). Keragaman siklus ini menjamin bahwa model LSTM teroptimasi diuji ketahanan dan daya generalisasinya secara menyeluruh (Tashman, 2000; Makridakis et al., 2018).

D. Instrumen Penelitian

Instrumen penelitian dalam ranah eksperimen komputasi kecerdasan buatan mencakup perangkat keras, perangkat lunak pemrograman, kerangka kerja pustaka pemodelan, serta instrumen formulasi matematis yang digunakan untuk mengeksekusi dan mengukur seluruh tahapan penelitian. Standarisasi instrumen komputasi menjadi prasyarat mutlak dalam penelitian sains data agar hasil

perhitungan numerik tidak mengalami penyimpangan akibat variasi spesifikasi dependensi perangkat. Instrumen ini dikelompokkan ke dalam tiga kategori utama, yaitu mesin komputasi perangkat keras untuk pemrosesan tensor, tumpukan perangkat lunak berbasis bahasa pemrograman Python, serta algoritma optimasi otomatis terstruktur (Creswell & Creswell, 2018; Goodfellow et al., 2016). Keterpaduan instrumen-instrumen ini memastikan eksperimen berlangsung secara stabil, presisi, serta memiliki tingkat keterulangan empiris yang sempurna di lingkungan komputasi sejenis (Bouthillier et al., 2021).

1. Perangkat Keras (Hardware)

Eksperimen komputasi pelatihan model dan penalaan hyperparameter dijalankan pada sebuah unit komputer stasiun kerja dengan arsitektur pemrosesan modern yang mampu menangani beban komputasi matriks berulang. Pelatihan arsitektur recurrent neural network melalui 50 siklus optimasi dengan skema validasi silang memerlukan stabilitas prosesor yang mumpuni agar tidak mengalami degradasi performa komputasi akibat panas berlebih. Komputer yang digunakan didukung oleh prosesor multi-core berbasis instruksi x86-64 dengan kecepatan frekuensi clock di atas 2.0 GHz per inti, dilengkapi memori akses acak (RAM) berkapasitas 8 GB untuk menampung struktur tensor berdimensi tiga selama pelatihan model berlangsung (Breuel, 2015). Media penyimpanan data mengandalkan Solid State Drive (SSD) bertransmisi tinggi guna mempercepat operasi baca dan tulis berkas dataset secara efisien (Goodfellow et al., 2016).

2. Perangkat Lunak dan Pustaka Pemrograman (Software)

Seluruh rangkaian pengembangan algoritma dan analisis data dibangun menggunakan bahasa pemrograman Python versi 3.10 atau lebih tinggi yang telah terbukti sebagai standar industri utama dalam riset pembelajaran mesin dan rekayasa data. Inkonsistensi versi pustaka sering kali menjadi faktor utama kegagalan reproduksi kode komputasi kecerdasan buatan, sehingga spesifikasi modul perangkat lunak perlu didefinisikan secara presisi. Pustaka TensorFlow dan antarmuka Keras digunakan untuk membangun lapisan sel LSTM dan mengelola kompilasi graf komputasi jaringan saraf tiruan (TensorFlow Developers, 2024).

Manipulasi larik matriks dan struktur data tabular dikelola menggunakan modul NumPy dan Pandas, transformasi data deret waktu dieksekusi dengan Scikit-learn, sementara visualisasi kurva evaluasi disusun menggunakan Matplotlib.

Tabel 3.2 Spesifikasi Instrumen Perangkat Lunak Penelitian

No	Perangkat Lunak / Pustaka	Versi Minimum	Fungsi dan Peranan Utama
1	Bahasa Python	Versi ≥ 3.10	Lingkungan eksekusi utama seluruh skrip pipeline eksperimen komputasi
2	TensorFlow / Keras	Versi ≥ 2.12	Konstruksi lapisan arsitektur LSTM, kompilasi loss, dan pelatihan model
3	Pustaka Optuna	Versi ≥ 3.3	Mesin optimasi hyperparameter otomatis berbasis TPE dan MedianPruner
4	Modul NumPy	Versi ≥ 1.24	Operasi matematis larik multidimensi dan kalkulasi metrik error evaluasi
5	Modul Pandas	Versi ≥ 2.0	Pengelolaan DataFrame, pembacaan berkas tabular CSV, dan manipulasi sekuens
6	Pustaka Scikit-learn	Versi ≥ 1.3	Implementasi penskalaan MinMaxScaler dan skema TimeSeriesSplit 5-fold
7	Modul Matplotlib	Versi ≥ 3.7	Visualisasi grafik prediksi deret waktu, kurva loss, dan konvergensi trial
8	Pustaka Requests	Versi ≥ 2.31	Ekstraksi data historis pasar spot melalui protokol HTTP Binance REST API

3. Instrumen Algoritma Optimasi (Optuna-TPE)

Instrumen algoritmik inti yang menjadi variabel perlakuan utama dalam penelitian ini adalah kerangka kerja Optuna yang mengintegrasikan algoritma pencarian probabilistik Tree-structured Parzen Estimator (TPE). Pendekatan optimasi konvensional seperti Grid Search mengalami kelemahan eksponensial terhadap jumlah parameter, sedangkan Random Search tidak memanfaatkan informasi evaluasi masa lalu untuk memandu pencarian berikutnya. Optuna memecahkan kendala ini melalui paradigma konstruksi ruang pencarian dinamis (Define-by-Run) dan pemodelan probabilistik Bayes non-parametrik yang secara adaptif memetakan wilayah konfigurasi hyperparameter yang menjanjikan (Bergstra et al., 2011; Akiba et al., 2019). Selain itu, keberadaan modul pemangkasan otomatis MedianPruner secara efisien memutus uji coba model yang berperforma buruk sebelum menyelesaikan seluruh putaran epoch, sehingga menghemat konsumsi waktu komputasi secara signifikan (Akiba et al., 2019).

E. Teknik Pengumpulan Data

Pengumpulan data primer harga perdagangan pasangan BTC/USDT dilaksanakan secara terprogram melalui protokol antarmuka Binance Public REST API memanfaatkan endpoint Kline/Candlestick Data dengan resolusi temporal harian (1d). Pengumpulan data secara manual menggunakan peramban web memiliki risiko kesalahan manusia yang tinggi serta ketidakseragaman struktur pencatatan stempel waktu. Peneliti menyusun skrip pengunduh otomatis berbasis modul Requests yang mengeksekusi panggilan API berulang dengan mekanisme paginasi berdasarkan stempel waktu Unix guna menjaring seluruh data historis dari awal 2020 hingga akhir 2025 (Binance Developer API, 2024). Setiap rekaman candlestick memuat atribut harga pembukaan (Open), tertinggi (High), terendah (Low), penutupan (Close), serta volume perdagangan (Volume) yang disimpan ke dalam format CSV terstruktur untuk keperluan analisis lanjutan (Hyndman & Athanasopoulos, 2018).

Segera setelah berkas data mentah berhasil dihimpun, peneliti menjalankan serangkaian prosedur audit kualitas data secara ketat tanpa melakukan interpolasi sintetis terhadap observasi yang hilang. Pada data finansial yang bervolatilitas tinggi, keberadaan anomali data berupa baris terduplikasi, nilai kosong (NaN), atau nilai tak terhingga (infinite) dapat merusak kestabilan gradien fungsi aktivasi pada model pembelajaran mendalam. Prosedur audit kualitas data mencakup lima pemeriksaan utama: kontinuitas stempel waktu harian tanpa celah, pengecekan ketiadaan rekaman ganda, verifikasi tipe data numerik presisi tinggi, serta validasi relasi geometris harga candlestick di mana harga High ≤ Open, Close dan Low ≤ Open, Close (Bouthillier et al., 2021). Hasil audit mengonfirmasi bahwa 2.192 data observasi berada dalam kondisi valid dan siap diproses ke tahap prapemrosesan (Hyndman & Athanasopoulos, 2018).

1. Preprocessing Data (Normalisasi Min-Max)

Tahap prapemrosesan data deret waktu diawali dengan melakukan penskalaan nilai fitur harga penutupan (Close) ke dalam rentang numerik seragam antara 0 dan 1 memanfaatkan metode normalisasi Min-Max Scaling. Fluktuasi

harga Bitcoin yang membentang sangat lebar dari level ribuan dolar hingga menembus puluhan ribu dolar dapat menyebabkan ketidakseimbangan pembaruan bobot serta memicu fenomena ledakan gradien pada fungsi aktivasi nonlinear LSTM. Melalui transformasi normalisasi ini, seluruh magnitudo nilai harga dikonversi ke dalam skala seragam yang kompatibel dengan karakteristik komputasi fungsi sigmoid dan tangensial hiperbolik pada gerbang internal LSTM (Goodfellow et al., 2016; Hochreiter & Schmidhuber, 1997). Formulasi matematis penskalaan Min-Max yang diterapkan dalam penelitian ini dinyatakan secara eksplisit pada Persamaan (3.1) sebagai berikut:

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}} \tag{3.1}$$

Pada formulasi Persamaan (3.1), variabel x melambangkan nilai harga penutupan asli, x_{min} dan x_{max} merepresentasikan nilai minimum dan maksimum historis data, serta x_{norm} adalah hasil nilai ternormalisasi pada rentang interval nol hingga satu. Penerapan normalisasi ini dijalankan dengan mematuhi protokol ketat pencegahan kebocoran informasi masa depan (anti-temporal data leakage), suatu kekeliruan umum di mana statistik seluruh data dihitung sebelum pemisahan sampel dilakukan. Dalam penelitian ini, nilai batas ekstrem x_{min} dan x_{max} dihitung secara eksklusif hanya dari data pelatihan (fit on training partition), lalu parameter skalar tersebut diterapkan untuk mentransformasikan data pengujian (transform on testing set) (López de Prado, 2018). Protokol ini memastikan bahwa model tidak pernah terpapar informasi skala masa depan sebelum peramalan dieksekusi (Arlot & Celisse, 2010; Tashman, 2000).

2. Pembentukan Jendela Data Sekuensial (Windowing)

Setelah proses normalisasi data selesai dilakukan, runtutan deret waktu satu dimensi ditransformasikan menjadi pasangan struktur masukan dan target keluaran sekuensial menggunakan teknik jendela geser (sliding window technique). Model jaringan syaraf berulang membutuhkan bentuk masukan berupa tensor berdimensi tiga yang memuat dimensi jumlah sampel, panjang langkah waktu, serta jumlah fitur guna mempelajari pola ketergantungan temporal. Untuk

setiap langkah waktu ke-t, vektor masukan X_t dibentuk dari L observasi historis masa lalu berurutan $[x_{t-L+1\},\ldots,x_t]$, sementara target keluaran y_t ditetapkan sebagai nilai harga pada langkah waktu tepat satu hari berikutnya x_{t+1} (Kervancı & Akay, 2023). Panjang jendela geser L (lookback window) merupakan salah satu hyperparameter kritis yang turut dioptimasi menggunakan Optuna guna menemukan konteks historis paling optimal bagi model LSTM (Lim & Zohren, 2021; Greff et al., 2017).

F. Teknis Analisis Data

Teknis analisis data dalam penelitian ini dirancang secara sistematis melalui pipeline komputasi terpadu yang mencakup enam komponen analitis utama guna menjawab rumusan masalah secara komprehensif. Ketiadaan struktur analisis yang baku sering kali menyebabkan pengujian model berjalan tidak konsisten sehingga sulit untuk mengidentifikasi faktor utama peningkatan performa. Komponen analisis ini mencakup: perancangan ruang pencarian hyperparameter, prosedur optimasi probabilistik Optuna-TPE, skema validasi temporal berpurge (Time-Series Split 5-fold, scaler per fold), matriks eksperimen terkontrol E0–E7, evaluasi statistik dengan moving-block bootstrap dan perbandingan berpasangan, serta analisis residual dan rezim pasar (Creswell & Creswell, 2018; Bouthillier et al., 2021). Setiap tahapan analitis dikonstruksi secara logis untuk menjamin bahwa kesimpulan akhir didasarkan pada bukti empiris yang kuat, terukur, dan dapat dipertanggungjawabkan secara ilmiah (Feurer & Hutter, 2019).

1. Definisi Ruang Pencarian Hyperparameter (Search Space)

Ruang pencarian (search space) hyperparameter arsitektur model LSTM dirumuskan secara terstruktur dengan mengacu pada sintesis literatur terkini mengenai faktor-faktor yang paling mempengaruhi generalisasi jaringan recurrent pada data finansial. Penentuan batas rentang pencarian yang terlalu sempit berpotensi mengabaikan konfigurasi terbaik, sedangkan batas yang terlalu luas memboroskan sumber daya komputasi pada wilayah parameter yang tidak realistis. Penelitian ini menetapkan enam hyperparameter kunci untuk dioptimasi:

panjang jendela historis (L), jumlah unit neuron per lapisan tersembunyi, tingkat regularisasi Dropout, laju pembelajaran (Learning Rate), ukuran batch komputasi (Batch Size), serta jumlah lapisan LSTM (Layers) sebagaimana dirangkum pada Tabel 3.3 (Kervancı & Akay, 2023; Greff et al., 2017). Penentuan domain distribusi mengombinasikan tipe diskret, kontinu logaritmik, dan kategorikal sesuai karakteristik parameter (Bergstra et al., 2011).

Tabel 3.3 Ruang Pencarian Hyperparameter LSTM pada Algoritma Optuna

No	Hyperparameter	Tipe Distribusi Optuna	Rentang Pencarian	Deskripsi dan Peranan
1	Lookback Window (L)	suggest_int	7 – 30 hari	Panjang sekuens domain-guided (siklus 1 minggu s.d. 1 bulan - Lo, 2004)
2	Hidden Units (per layer)	suggest_int	32 – 128 neuron	Kapasitas representasi fitur tersembunyi tanpa over-parametrization
3	Dropout Rate	suggest_float	0.1 – 0.4	Probabilitas eliminasi acak koneksi neuron untuk meredam overfitting
4	Learning Rate	suggest_float (log)	5×10^{-4} – 2×10^{-3}	Laju langkah penyesuaian gradien bobot sinapsis optimizer Adam (Kingma & Ba, 2014)
5	Batch Size	suggest_categorical	[16, 32, 64]	Jumlah sampel observasi yang diproses per pembaruan gradien loss
6	Layers	suggest_int	1 – 2 lapisan	Kedalaman arsitektur LSTM untuk menyesuaikan kapasitas abstraksi model

Kedalaman arsitektur LSTM dieksplorasi secara dinamis antara satu hingga dua lapisan berulang (stacked layers) guna menyesuaikan kapasitas abstraksi model terhadap kompleksitas volatilitas harga Bitcoin secara terukur. Algoritma optimasi Adam ditetapkan konstan sebagai optimizer karena mekanisme penyesuaian laju pembelajaran adaptif berbasis momen orde pertama dan kedua terbukti stabil pada data deret waktu yang rentan derau acak (Kingma & Ba, 2014). Pada E7, fungsi kerugian yang diminimalkan adalah Mean Absolute Error (MAE) yang selaras dengan metrik evaluasi utama, didukung Early Stopping dan ReduceLROnPlateau. Namun, matriks E3–E6 sengaja memvariasikan loss dan scheduler untuk menguji apakah kedua faktor tersebut benar-benar memberi

perbaikan, sehingga konfigurasi E7 tidak diasumsikan unggul sebelum diuji secara empiris (Srivastava et al., 2014; Goodfellow et al., 2016).

2. Prosedur Optimasi Algoritma Optuna-TPE

Proses penalaan hyperparameter dijalankan secara otomatis menggunakan kerangka kerja Optuna dengan total anggaran komputasi sebanyak 50 uji coba (trials) yang dipandu oleh algoritma Tree-structured Parzen Estimator (TPE). Pendekatan brute-force maupun pencarian acak mengabaikan riwayat uji coba masa lalu, sehingga kerap kali terjebak pada wilayah hyperparameter dengan performa yang buruk. Melalui pemodelan Bayes non-parametrik, TPE mengelompokkan riwayat uji coba terdahulu ke dalam dua distribusi kepadatan probabilitas, yaitu kelompok konfigurasi terbaik $\ell(x)$ dan kelompok konfigurasi lainnya $g(x)$ berdasarkan nilai persentil kerugian validasi (Bergstra et al., 2011; Akiba et al., 2019). Kandidat titik konfigurasi baru selanjutnya diambil dari wilayah yang memaksimalkan rasio $\ell(x)/g(x)$, sehingga proses eksplorasi bergerak secara cerdas menuju ruang pencarian yang berpotensi menghasilkan error minimum (Feurer & Hutter, 2019).

Efisiensi eksekusi komputasi selama 50 uji coba optimasi ditingkatkan secara substansial melalui integrasi strategi pemangkasan cerdas berbasis modul MedianPruner bawaan Optuna. Menjalankan seluruh lipatan validasi pada konfigurasi hyperparameter yang sejak awal menunjukkan performa buruk hanya akan menghabiskan waktu dan sumber daya komputasi. Pada setiap akhir lipatan, fungsi objektif melaporkan nilai MAE validasi kepada Optuna; MedianPruner kemudian membandingkannya dengan nilai median uji coba sebelumnya pada langkah lipatan yang sama (Akiba et al., 2019). Apabila kinerja uji coba berada di atas median galat, Optuna menghentikan sisa lipatan dan mengalokasikan komputasi ke kandidat berikutnya. Mekanisme ini bekerja pada tingkat lipatan validasi, bukan pada setiap epoch pelatihan internal, sehingga keputusan pruning konsisten dengan protokol evaluasi deret waktu (Akiba et al., 2019; Optuna Development Team, 2024).

3. Skema Validasi Deret Waktu (Time-Series Split)

Evaluasi keandalan model selama proses optimasi hyperparameter dilakukan dengan menerapkan skema validasi silang deret waktu (Time-Series Split) sebanyak 5 lipatan (folds) secara ketat tanpa pengacakan data. Penggunaan metode K-Fold Cross-Validation konvensional yang lazim diterapkan pada data statis sangat dilarang dalam analisis deret waktu karena proses pengacakan observasi akan melanggar prinsip kausalitas temporal serta menimbulkan ilusi akurasi yang bias (data snooping). Pada skema Time-Series Split, data diurutkan secara kronologis di mana pada setiap lipatan ke- k , data pelatihan hanya menggunakan observasi masa lalu sebelum titik potong temporal ke-k, sedangkan data validasi dievaluasi pada jendela waktu berikutnya (Arlot & Celisse, 2010; Tashman, 2000). Setiap lipatan menyisipkan purge gap sebesar lookback dan scaler Min-Max di-fit ulang hanya pada jendela latih lipatan tersebut, sehingga tidak ada observasi masa depan yang bocor ke pelatihan. Nilai validasi dihitung dalam satuan USD dan rata-rata lintas lima lipatan dijadikan fungsi objektif yang diminimalkan oleh Optuna (Wahyuddin dkk., 2025).

Secara keseluruhan, dataset penelitian dipartisi secara berurutan menurut garis waktu kronologis menjadi dua segmen utama dengan rasio 80:20, yaitu segmen data latih-validasi (in-sample) dan data uji akhir (out-of-sample). Pemisahan ini mutlak diperlukan untuk mencegah terjadinya bias seleksi (selection bias) di mana model dievaluasi pada data yang turut terlibat dalam pemilihan konfigurasi hyperparameter terbaik. Sebanyak 80% data awal (1.753 observasi) digunakan secara eksklusif untuk proses pelatihan dan validasi silang lima lipatan Optuna, sementara 20% data sisanya (439 observasi perdagangan terakhir) dicadangkan sebagai data uji holdout murni yang terkunci (López de Prado, 2018). Model dengan arsitektur terbaik hasil optimasi Optuna kemudian diuji kemampuannya pada segmen out-of-sample ini untuk mengukur akurasi peramalan yang objektif (Hyndman & Athanasopoulos, 2018; Makridakis et al., 2018).

4. Desain Matriks Eksperimen Terkontrol (E0–E7)

Kinerja model usulan dievaluasi melalui matriks E0 sampai E7 yang dijalankan pada data uji yang sama persis. Struktur ini memastikan klaim tidak hanya dibandingkan dengan konfigurasi yang lemah, tetapi diuji terhadap baseline naif, kontrol default, replikasi literatur, dan ablasi faktor pelatihan. E0 adalah persistence, E1 memakai konfigurasi default Tier 1, E2 mereplikasi penalaan manual Khumaidi dkk. (2024), dan E3 sampai E6 membekukan parameter Tier 3 sambil memvariasikan loss serta scheduler dalam desain faktorial 2x2. E7 adalah model usulan yang menjalani HPO penuh dengan Optuna-TPE, sehingga perbandingan E7 terhadap E6 mengisolasi nilai tambah HPO itu sendiri (Bouthillier et al., 2021). Rincian setiap run disajikan pada Tabel 3.4 (Makridakis et al., 2018).

Tabel 3.4 Matriks Eksperimen Terkontrol E0–E7

Run	Model dan Konfigurasi	Loss / Scheduler	Peran dalam Matriks
E0	Persistence (random walk)	Tanpa pelatihan	Baseline naif; ambang minimum
E1	Tier 1 default: L30, U50, D0.20, LR0.001, B32, 1 layer	MSE / tanpa	Kontrol default
E2	Tier 2 manual (Khumaidi dkk.): L60, U128, D0.20, LR0.001, B10, 1 layer	MSE / tanpa	Rujukan literatur
E3	Parameter Tier 3 acuan: L22, U100, D0.10, LR0.001966, B16, 1 layer	MSE / tanpa	Referensi ablasi
E4	Parameter Tier 3 acuan	MAE / tanpa	Ablasi loss
E5	Parameter Tier 3 acuan	MSE / plateau	Ablasi scheduler
E6	Parameter Tier 3 acuan	MAE / plateau	Ablasi gabungan
E7	HPO Optuna-TPE: L7–30, U32–128, D0.10–0.40, LR5e-4–2e-3, B16/32/64, 1–2 layer	MAE / plateau	Model usulan

Keterangan: L = lookback (hari), U = hidden units, D = dropout, LR = learning rate, dan B = batch size. E1 sampai E6 memakai konfigurasi tetap dan Early Stopping patience 12, sedangkan E7 memilih konfigurasi melalui Optuna-TPE dengan ruang pencarian pada Tabel 3.3. Seluruh run memakai partisi, tanggal holdout, dan protokol evaluasi yang identik agar perbedaan metrik hanya berasal dari perlakuan yang diuji.

5. Metrik Evaluasi Kinerja Model dan Persentase Penurunan Error

Kemampuan peramalan seluruh model dalam matriks E0–E7 dievaluasi secara kuantitatif menggunakan tiga metrik pengukuran galat komputasi standar, yaitu Root Mean Square Error (RMSE), Mean Absolute Error (MAE), serta Mean Absolute Percentage Error (MAPE). Mengandalkan satu metrik tunggal berpotensi menghasilkan kesimpulan yang bias karena setiap formulasi matematis memiliki sensitivitas yang berlainan terhadap magnitudo dan deviasi data ekstrim. Metrik RMSE memberikan penalti berbobot kuadratik yang lebih tegas terhadap kesalahan bernilai besar, MAE mengukur deviasi rata-rata absolut linier yang intuitif, sedangkan MAPE merepresentasikan proporsi persentase kesalahan relatif terhadap nilai aktual harga (Willmott & Matsuura, 2005; Hyndman & Athanasopoulos, 2018). Evaluasi multi-metrik ini dihitung secara eksklusif pada data pengujian out-of-sample untuk memastikan akurasi penilaian generalisasi model (Gu et al., 2020). MAE ditetapkan sebagai metrik utama karena skalanya langsung dapat dibaca dalam USD, sedangkan RMSE dan MAPE berfungsi sebagai pemeriksaan sensitivitas. Setiap model dijalankan pada lima seed, dan interval kepercayaan 95% dihitung dengan moving-block bootstrap tujuh hari sebanyak 2.000 resampel pada tanggal yang sama; perbedaan berpasangan baru disebut unggul bila selisih MAE negatif dan seluruh intervalnya berada di bawah nol (Willmott & Matsuura, 2005; Tashman, 2000).

$$Improvement\ (\%) = \frac{Error_{baseline} - Error_{optimized}}{Error_{baseline}} \times 100 \qquad (3.2)$$

Tingkat signifikansi keberhasilan optimasi diukur secara matematis melalui persentase perbaikan performa (Improvement Percentage) terhadap masing-masing baseline acuan sebagaimana dirumuskan pada Persamaan (3.2). Perbedaan nilai absolut error sering kali sulit diinterpretasikan antar-skenario pengujian yang berbeda, sehingga diperlukan standarisasi pengukuran penurunan error yang proporsional. Pada persamaan tersebut, variabel $Error_{baseline}$ menyatakan nilai metrik galat (RMSE, MAE, atau MAPE) dari model pembanding, sedangkan $Error_{optimized}$ melambangkan nilai galat model yang dievaluasi (Willmott & Matsuura, 2005). Nilai persentase perbaikan yang bertanda positif hanya

bermakna bila arah selisih dan interval kepercayaan berpasangan mendukungnya; angka persentase tunggal tidak dipakai sebagai bukti signifikansi. Dengan demikian, efek HPO, loss, dan scheduler dibaca bersama variabilitas antar-seed, bukan hanya dari satu nilai terbaik (Makridakis et al., 2018; Bouthillier et al., 2021).

6. Alur Prosedur Penelitian Secara Keseluruhan

Secara komprehensif, seluruh rangkaian pelaksanaan penelitian dari tahap inisiasi konseptual hingga penarikan kesimpulan akhir diintegrasikan ke dalam tujuh tahapan kerja sekuensial yang saling berkesinambungan. Penyusunan alur kerja yang terstandar menjamin bahwa seluruh proses manipulasi data dan eksekusi komputasi berjalan secara terkontrol tanpa distorsi metodologis. Tujuh tahapan kerja tersebut mencakup: akuisisi data historis via Binance API, audit kualitas dan normalisasi Min-Max, pemisahan partisi data in-sample dan out-of-sample, penalaan 50 trials Optuna-TPE dengan Time-Series Split 5-fold berpurge, pelatihan seluruh model pada lima seed, pengujian matriks E0–E7, serta analisis residual, rezim, dan perbandingan berpasangan (Tabel 3.5) (Creswell & Creswell, 2018; Tashman, 2000). Rangkaian tahapan ini menegakkan keterulangan empiris serta keabsahan ilmiah dari model peramalan harga Bitcoin yang dikembangkan (Bouthillier et al., 2021).

Tabel 3.5 Ringkasan Alur Prosedur Pelaksanaan Penelitian

Tahap	Aktivitas Metodologis	Keluaran (Output)	Instrumen / Modul
1	Pengumpulan Data Historis	Dataset mentah BTC/USDT OHLCV (2.192 baris)	Binance Public REST API, Requests
2	Audit & Prapemrosesan	Data bersih ternormalisasi [0, 1] & tensor sekuen	Pandas, NumPy, Scikit-learn
3	Partisi Data Bebas Bocor	1.753 in-sample dan 439 out-of-sample	Python, Pandas, Slicing temporal
4	Optimasi Hyperparameter	Konfigurasi E7 hasil 50 trials & 5-fold CV berpurge	Optuna, TPE Sampler, MedianPruner
5	Pelatihan Seluruh Model	Bobot LSTM untuk E1–E7 pada lima seed	TensorFlow/Keras, EarlyStopping
6	Evaluasi Out-of-Sample	Metrik RMSE, MAE, dan MAPE seluruh model	Scikit-learn, NumPy, Matplotlib
7	Analisis Komparatif	Matriks E0–E7, CI bootstrap, dan analisis rezim	Python, moving-block bootstrap

BAB IV
HASIL PENELITIAN DAN PEMBAHASAN

A. Hasil Penelitian

Bab ini melaporkan hasil matriks eksperimen terkontrol E0 sampai E7 untuk peramalan harga penutupan Bitcoin satu langkah ke depan. Seluruh model dievaluasi pada 439 hari holdout yang identik, sedangkan pemilihan hyperparameter, early stopping internal, dan seluruh keputusan desain hanya menggunakan 1.753 observasi in-sample. Angka yang disajikan pada tabel dan paragraf dibaca langsung dari berkas hasil final yang tersimpan, bukan dari ingatan peneliti atau tabel lama. Dengan demikian, setiap klaim dapat ditelusuri kembali ke run, seed, dan berkas metrik yang menghasilkan angka tersebut (Bouthillier et al., 2021).

1. Karakteristik Data dan Protokol Evaluasi

Data primer berupa harga penutupan harian BTC/USDT periode 2020-01-01 sampai 2025-12-31 dengan total 2.192 observasi. Harga terendah tercatat USD 4.800,00 pada 2020-03-12, sedangkan harga tertinggi USD 124.658,54 pada 2025-10-06. Rata-rata harga adalah USD 47.182,88, median USD 39.732,62, dan simpangan baku USD 31.418,23. Rentang harga yang lebar menunjukkan bahwa model harus bekerja pada rezim pasar yang sangat berbeda, sehingga evaluasi tunggal pada satu periode tidak cukup untuk menggeneralisasi ke seluruh siklus Bitcoin (Makridakis et al., 2018).

Tabel 4.1 Statistik Deskriptif Harga Penutupan Bitcoin

No	Parameter	Nilai	Keterangan
1	Total observasi	2.192 hari	Data harian tanpa celah
2	Harga minimum	USD 4.800,00	Tercatat 2020-03-12
3	Harga maksimum	USD 124.658,54	Tercatat 2025-10-06
4	Rata-rata	USD 47.182,88	Rerata aritmatika
5	Median	USD 39.732,62	Titik tengah distribusi
6	Simpangan baku	USD 31.418,23	Dispersi harga

Partisi data dilakukan secara kronologis 80:20 tanpa pengacakan: 1.753 observasi in-sample, lalu 439 observasi holdout mulai 2024-10-19 sampai 2025-12-31. Holdout tidak pernah dibaca selama tuning. Pada Tier 3, validasi silang

menggunakan Time-Series Split berpurge dengan jarak sebesar lookback dan scaler Min-Max yang di-fit ulang pada setiap fold. Interval kepercayaan dihitung dengan moving-block bootstrap 7 hari sebanyak 2.000 resample pada tanggal yang sama, sedangkan variabilitas antar-seed dilaporkan terpisah sebagai mean dan simpangan baku dari lima seed (Arlot & Celisse, 2010; Tashman, 2000).

2. Baseline Persistence dan Baseline Naif

Baseline persistence memprediksi harga besok sama dengan harga hari ini. Pada holdout, baseline ini menghasilkan RMSE USD 2.167,24, MAE USD 1.579,80, dan MAPE 1,62%. Interval kepercayaan 95% untuk MAE persistence adalah USD 1.437,83 sampai USD 1.742,58. Nilai tersebut menjadi ambang minimum yang harus dikalahkan sebelum sebuah model LSTM layak disebut bermanfaat. Baseline drift dan seasonal naive juga dilaporkan pada Tabel 4.2 untuk menunjukkan bahwa kesimpulan tidak bergantung pada satu pembanding yang lemah (Hyndman & Athanasopoulos, 2018; Makridakis et al., 2018).

Tabel 4.2 Kinerja Baseline Naif pada Holdout

Baseline	RMSE	MAE	MAPE
Persistence	USD 2.167,24	USD 1.579,80	1,62%
Drift	USD 2.166,82	USD 1.579,59	1,62%
Seasonal Naive 7	USD 5.404,67	USD 4.128,13	4,22%
Moving Average 7	USD 3.484,84	USD 2.645,28	2,71%

3. Model Kontrol Tier 1 dan Tier 2

Model kontrol Tier 1 memakai konfigurasi default, sedangkan Tier 2 mereplikasi konfigurasi manual Khumaidi dkk. (2024). Tier 1 menghasilkan MAE USD 1.968,00 dan Tier 2 menghasilkan MAE USD 2.892,27. Keduanya masih lebih tinggi daripada persistence yang memiliki MAE USD 1.579,80, sehingga menambah kapasitas atau mengikuti resep manual tidak otomatis mengalahkan baseline naif pada horizon satu hari. Perubahan MAE Tier 1 terhadap persistence adalah peningkatan galat 24,57%, sedangkan Tier 2 terhadap persistence adalah peningkatan galat 83,08%. Perbandingan ini penting karena posisi kedua kontrol terhadap baseline menentukan apakah ablasi berikutnya benar-benar memperbaiki titik acuan yang bermakna (Khumaidi dkk., 2024; Willmott & Matsuura, 2005).

4. Ablasi Loss dan Scheduler pada Parameter Tier 3

Ablasi E3 sampai E6 membekukan parameter Tier 3 dan hanya memvariasikan fungsi kerugian serta scheduler dalam desain faktorial 2x2. E3 memakai MSE tanpa scheduler dan menghasilkan MAE USD 2.452,53. E4 memakai MAE tanpa scheduler dengan MAE USD 1.763,47, sedangkan E5 memakai MSE dengan ReduceLROnPlateau dan MAE USD 2.043,10. Kombinasi keduanya pada E6 menghasilkan MAE USD 1.667,26. Dengan demikian, perubahan MAE E4 terhadap E3 adalah perbaikan 28,10%, E5 terhadap E3 adalah perbaikan 16,69%, dan E6 terhadap E3 adalah perbaikan 32,02%.

Tabel 4.3 Hasil Ablasi Loss dan Scheduler

Run	Loss / Scheduler	RMSE	MAE	MAPE	Delta MAE vs E3
E3	MSE / Tanpa	USD 2.994,73	USD 2.452,53	2,43%	+0,00%
E4	MAE / Tanpa	USD 2.328,70	USD 1.763,47	1,79%	+28,10%
E5	MSE / Plateau	USD 2.591,70	USD 2.043,10	2,05%	+16,69%
E6	MAE / Plateau	USD 2.234,46	USD 1.667,26	1,70%	+32,02%

Pola pada Tabel 4.3 menunjukkan bahwa efek loss dan scheduler tidak selalu bersifat aditif. Bila delta E4 positif, fungsi kerugian MAE menurunkan galat absolut rata-rata dibandingkan MSE pada parameter yang sama. Bila delta E5 positif, scheduler memberi perbaikan meskipun loss tetap MSE. Efek gabungan pada E6 kemudian dibandingkan dengan E4 dan E5 untuk melihat apakah kedua faktor saling memperkuat atau justru mengganggu. Interpretasi dilakukan pada arah dan besaran efek, bukan pada klaim kausal tentang mekanisme internal jaringan, karena ablation ini hanya mengubah dua faktor pada satu konfigurasi parameter (Bouthillier et al., 2021; Greff et al., 2017).

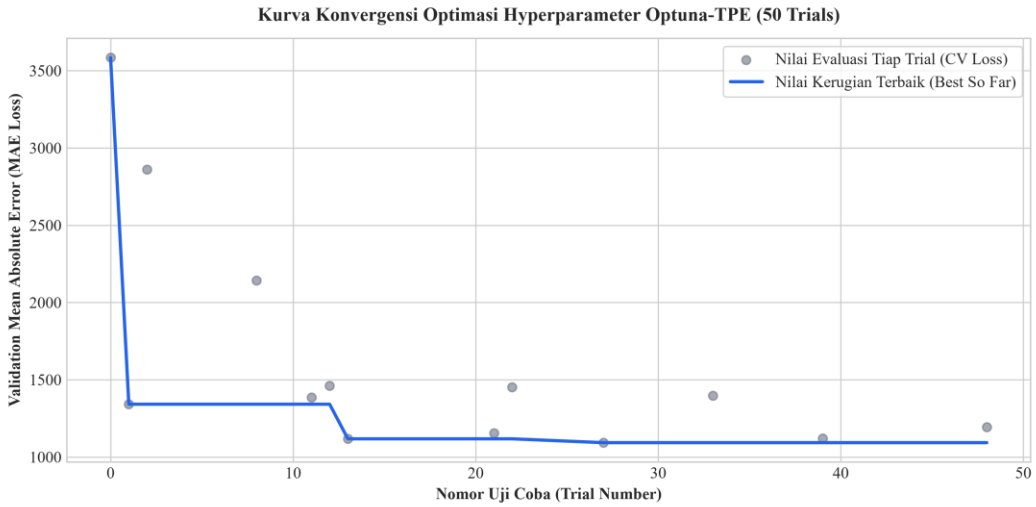
5. Hasil HPO Bersih Tier 3 (E7)

E7 adalah model usulan yang menjalani HPO penuh dengan Optuna-TPE. Studi menyelesaikan 50 trial dan memilih trial nomor 27 dengan nilai CV MAE 1.092,79 USD. Konfigurasi terpilih memakai lookback 25 hari, 112 unit LSTM, dropout 0,10, learning rate 0,00128, batch size 16, dan 1 layer. Model final dilatih selama 100 epoch dengan EarlyStopping patience 12.

Tabel 4.4 Konfigurasi Final Model Usulan E7

Parameter	Nilai Terpilih	Peran
Lookback	25 hari	Panjang jendela masukan
Hidden units	112	Kapasitas representasi
Dropout	0,10	Regularisasi
Learning rate	0,00128	Laju Adam
Batch size	16	Ukuran minibatch
Layers	1	Kedalaman LSTM
Total trials	50	Anggaran HPO
Trial terbaik	#27	Indeks Optuna (mulai 0)
Epoch final	100	Hasil EarlyStopping

Pada holdout, E7 menghasilkan RMSE USD 2.250,06, MAE USD 1.687,49, dan MAPE 1,72%. Interval kepercayaan 95% untuk MAE E7 adalah USD 1.560,55 sampai USD 1.841,42. Sebagai pembanding, E6 yang memakai parameter Tier 3 tetap tanpa HPO menghasilkan MAE USD 1.667,26. Perubahan MAE E7 terhadap E6 adalah peningkatan galat 1,21%, sedangkan perubahan terhadap persistence adalah peningkatan galat 6,82%. Angka ini menjadi dasar penilaian apakah HPO penuh memberi nilai tambah di luar pemilihan loss dan scheduler (Akiba et al., 2019; Feurer & Hutter, 2019).



Gambar 4.1 Kurva Konvergensi Nilai Validasi Optuna-TPE

6. Perbandingan Statistik dan Verdict Ilmiah

Tabel 4.5 merangkum seluruh model. Model LSTM terbaik menurut MAE adalah E6 dengan MAE USD 1.667,26, sedangkan persistence memiliki MAE USD 1.579,80. Untuk E7, selisih MAE terhadap persistence adalah USD +107,69 dengan CI 95% USD +50,82 sampai USD +170,90. Verdict otomatis menyatakan bahwa E7 memiliki MAE lebih tinggi daripada persistence dan CI selisih

berpasangan seluruhnya di atas nol. Dengan demikian, hasil ini bukan sekadar tidak lebih baik, tetapi secara statistik lebih buruk pada periode holdout yang diuji. Hasil negatif ini dilaporkan apa adanya: model LSTM yang dioptimasi belum mampu mengalahkan baseline naif pada horizon satu hari. Kontribusi penelitian kemudian bergeser menjadi pipeline evaluasi dan bukti terkontrol tentang batas kemampuan LSTM, bukan klaim keunggulan prediktif.

Tabel 4.5 Perbandingan Kinerja Seluruh Model pada Holdout

Run	Model	RMSE	MAE	MAPE	MAE mean ± std	CI 95% MAE
E0	Persistence	USD 2.167,24	USD 1.579,80	1,62%	USD 1.579,80 ± 0,00	USD 1.437,83–USD 1.742,58
E1	Tier 1 default	USD 2.519,46	USD 1.968,00	1,98%	USD 2.058,81 ± 196,57	USD 1.823,08–USD 2.150,40
E2	Tier 2 manual	USD 3.491,05	USD 2.892,27	2,87%	USD 3.048,39 ± 399,48	USD 2.688,41–USD 3.169,33
E3	Ablasi MSE / tanpa scheduler	USD 2.994,73	USD 2.452,53	2,43%	USD 2.281,38 ± 163,11	USD 2.280,41–USD 2.672,47
E4	Ablasi MAE / tanpa scheduler	USD 2.328,70	USD 1.763,47	1,79%	USD 1.790,80 ± 167,38	USD 1.633,82–USD 1.927,38
E5	Ablasi MSE / ReduceLROnPlateau	USD 2.591,70	USD 2.043,10	2,05%	USD 2.116,59 ± 78,61	USD 1.902,38–USD 2.225,68
E6	Ablasi MAE / ReduceLROnPlateau	USD 2.234,46	USD 1.667,26	1,70%	USD 1.712,07 ± 67,48	USD 1.537,90–USD 1.825,72
E7	Tier 3 HPO penuh (usulan)	USD 2.250,06	USD 1.687,49	1,72%	USD 1.756,11 ± 89,97	USD 1.560,55–USD 1.841,42

Tabel 4.6 Perbandingan Berpasangan pada Tanggal yang Sama

Perbandingan	Selisih MAE (B - A)	CI 95%	CI jauh dari nol?
E0 vs E7	USD +107,69	USD +50,82–USD +170,90	Tidak
E6 vs E7	USD +20,23	USD +1,22–USD +40,37	Tidak
E1 vs E3	USD +484,54	USD +349,10–USD +627,30	Tidak
E3 vs E4	USD -689,06	USD -839,71–USD -552,16	Ya
E3 vs E5	USD -409,43	USD -533,89–USD -293,39	Ya
E3 vs E6	USD -785,27	USD -960,55–USD -627,88	Ya

Perbandingan berpasangan pada Tabel 4.6 memakai tanggal yang sama untuk setiap model, sehingga perbedaan tidak tercampur dengan perbedaan komposisi hari. Selisih negatif berarti model B memiliki galat lebih rendah. Kolom terakhir hanya menyatakan apakah seluruh interval kepercayaan berada di bawah nol; nilai p yang menyertainya bersifat deskriptif dan bukan pengganti uji formal Diebold-Mariano. Pembacaan yang benar adalah membandingkan arah efek, besar efek, dan lebar interval secara bersama-sama, bukan memilih satu angka yang paling menguntungkan (Bouthillier et al., 2021; Willmott & Matsuura, 2005).

7. Analisis Residual, Rezim, dan Arah

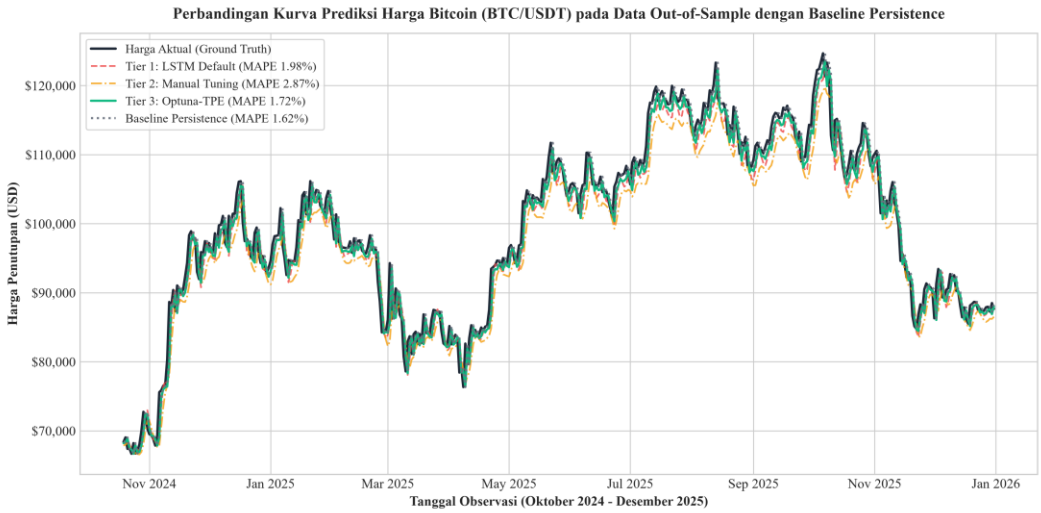
Residual E7 memiliki rata-rata USD +653,66 dan simpangan baku USD 2.153,02. Galat absolut maksimum mencapai USD 8.791,29, sedangkan proporsi hari dengan galat di bawah 2% adalah 69,48%. Pada rezim bull, MAE E7 adalah USD 1.658,64; pada rezim bear USD 1.908,72; dan pada sideways USD 1.549,76. Pada hari berivolatilitas tinggi, MAE USD 3.099,31, sedangkan pada hari normal USD 1.598,61.

Tabel 4.7 Kinerja E7 Menurut Rezim dan Volatilitas (Label Ex-Ante)

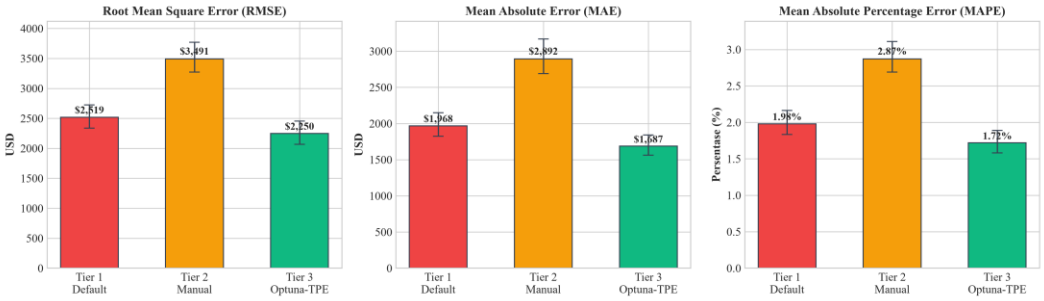
Segmen	n	RMSE	MAE	MAPE
Bull	163	USD 2.256,91	USD 1.658,64	1,67%
Bear	119	USD 2.535,42	USD 1.908,72	2,06%
Sideways	157	USD 1.998,92	USD 1.549,76	1,50%
Volatilitas tinggi	26	USD 4.049,64	USD 3.099,31	3,63%
Volatilitas normal	413	USD 2.085,44	USD 1.598,61	1,60%

Label rezim dan volatilitas dihitung dari data yang berakhir pada hari sebelumnya, sehingga tidak memakai informasi hari yang diprediksi. Karena itu, tabel ini berfungsi sebagai analisis pasca-hoc untuk melihat di mana galat membesar, bukan sebagai fitur model atau klaim kausal. Perbedaan MAE antar-rezim menunjukkan bahwa satu angka agregat dapat menyembunyikan heterogenitas: model yang tampak moderat pada seluruh holdout dapat sangat buruk pada bull market atau sebaliknya. Pembacaan seperti ini penting sebelum model dipakai untuk keputusan investasi (López de Prado, 2018; Lim & Zohren, 2021).

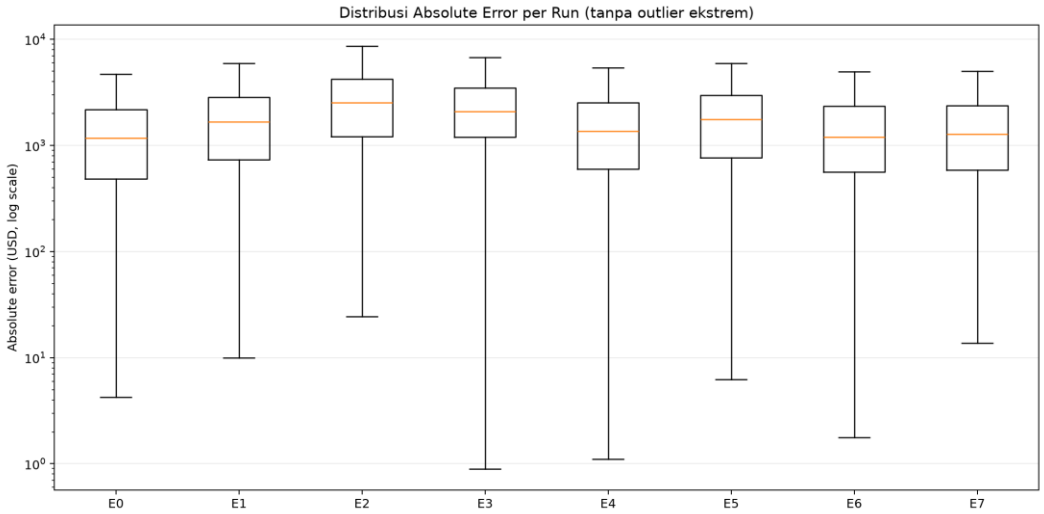
Akurasi arah E7 adalah 50,57% dengan 222 dari 439 hari benar. Pada hari harga naik, akurasi hanya 3,59%, sedangkan pada hari harga turun 99,07%. Ketimpangan ini menunjukkan bahwa angka agregat sekitar 50% tidak mencerminkan kemampuan dua arah yang seimbang, melainkan bias arah yang kuat. Angka ini juga tidak boleh dibandingkan langsung dengan persistence, karena persistence selalu memprediksi harga yang sama sehingga arah prediksinya degenerat dan akurasinya dilaporkan terpisah sebagai tidak interpretable. Untuk model LSTM, pola ini menunjukkan bahwa kemampuan menangkap tanda perubahan harga masih terbatas, bahkan ketika galat harga dalam dolar terlihat moderat (Hyndman & Athanasopoulos, 2018).



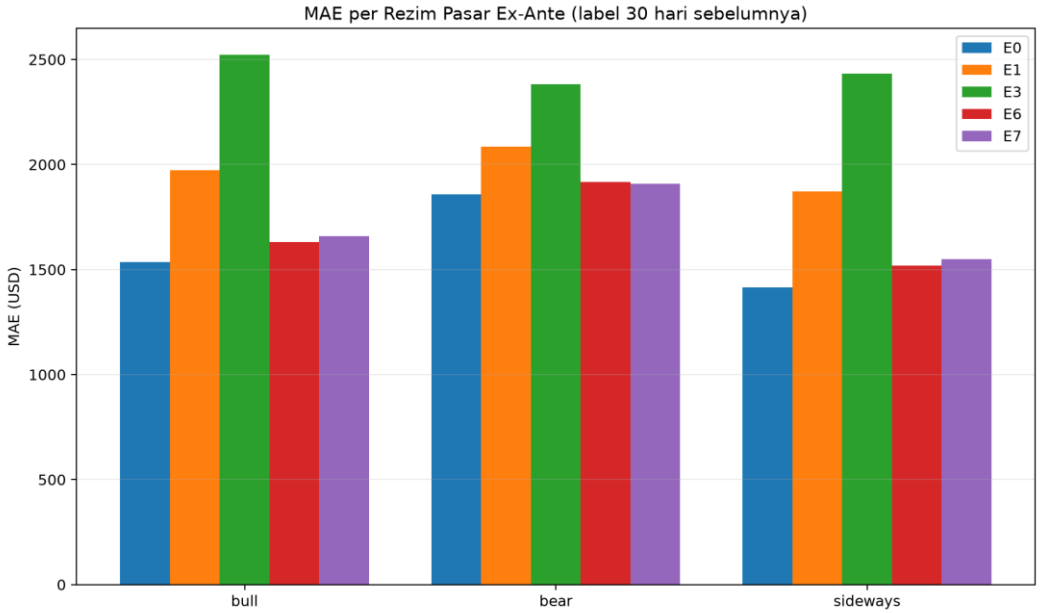
Gambar 4.2 Perbandingan Harga Aktual dan Prediksi pada Holdout



Gambar 4.3 Diagram Batang Perbandingan Metrik



Gambar 4.4 Distribusi Galat Absolut Menurut Model



Gambar 4.5 Galat Menurut Rezim Pasar

B. Pembahasan Hasil Penelitian

Pembahasan ini menghubungkan hasil numerik dengan teori peramalan deret waktu dan literatur optimasi hyperparameter. Fokusnya bukan memilih model yang paling menguntungkan untuk diklaim, melainkan menjelaskan mengapa pola hasil muncul dan apa batas kesimpulan yang dapat ditarik. Tiga pertanyaan dibahas: mengapa persistence sulit dikalahkan, apakah faktor loss, scheduler, dan HPO memberi efek yang dapat dipisahkan, dan apa implikasi serta keterbatasan hasil ini bagi penelitian lanjutan (Bouthillier et al., 2021; Makridakis et al., 2018).

1. Mengapa Baseline Persistence Sulit Dikalahkan

Persistence efektif mengasumsikan bahwa perubahan harga harian memiliki ekspektasi mendekati nol. Pada aset likuid dengan perdagangan twenty-four seven seperti Bitcoin, asumsi ini sering sulit dikalahkan oleh model yang hanya melihat harga masa lalu, terutama pada horizon satu hari. Hasil penelitian ini konsisten dengan pola tersebut: seluruh model LSTM memiliki MAE di atas USD 1.579,80. Fenomena ini bukan berarti LSTM tidak berguna, tetapi menunjukkan bahwa

sinyal prediktif harian yang tersedia pada data univariat sangat kecil dibandingkan derau pasar (Makridakis et al., 2018; Lim & Zohren, 2021).

Kekalahan model yang lebih kompleks juga dapat dijelaskan oleh kombinasi non-stasioneritas, perubahan rezim, dan keterbatasan horizon. Model dilatih pada periode in-sample yang mencakup kondisi pasar berbeda, lalu diuji pada periode yang didominasi harga tinggi. Pergeseran distribusi ini membuat bobot yang optimal secara historis belum tentu optimal pada holdout. Baseline persistence tidak memiliki parameter yang harus diperbarui, sehingga lebih tahan terhadap pergeseran tersebut. Temuan ini menegaskan pentingnya melaporkan baseline naif secara eksplisit sebelum mengklaim kemajuan algoritma (Bouthillier et al., 2021; Gu et al., 2020).

2. Efek Hyperparameter Optuna: E1 versus E3

Perbandingan E1 dan E3 mengisolasi efek hyperparameter karena keduanya memakai MSE dan tanpa scheduler. E1 memiliki MAE USD 1.968,00, sedangkan E3 memiliki MAE USD 2.452,53. selisih MAE E3 − E1 adalah USD +484,54, dengan CI 95% selisih USD +349,10 sampai USD +627,30 yang tidak melewati nol; E1 mencatat MAE lebih rendah daripada E3. Arah ini menunjukkan bahwa konfigurasi hasil pencarian Optuna tidak otomatis lebih baik daripada konfigurasi default ketika loss dan aturan pelatihan disamakan. Klaim bahwa Optuna selalu menghasilkan hyperparameter yang lebih unggul perlu dihindari; yang dapat dikatakan adalah bahwa efek HPO bergantung pada ruang pencarian, metrik objektif, dan interaksi dengan faktor pelatihan lain (Akiba et al., 2019; Bergstra et al., 2011).

3. Efek Loss MAE dan Scheduler

Pada E4, penggantian MSE dengan MAE tanpa scheduler mengubah MAE dari USD 2.452,53 menjadi USD 1.763,47. selisih MAE E4 − E3 adalah USD -689,06, dengan CI 95% selisih USD -839,71 sampai USD -552,16 yang tidak melewati nol; E4 mencatat MAE lebih rendah daripada E3. Arah ini sejalan dengan tujuan MAE yang mengoptimalkan galat absolut, tetapi besarnya efek

tetap harus dibaca bersama variabilitas antar-seed. Sebaliknya, E5 menguji scheduler tanpa mengubah loss dan menghasilkan MAE USD 2.043,10. selisih MAE E5 − E3 adalah USD -409,43, dengan CI 95% selisih USD -533,89 sampai USD -293,39 yang tidak melewati nol; E5 mencatat MAE lebih rendah daripada E3. Scheduler menurunkan MAE titik sebesar USD 409,43, tetapi besar efeknya lebih kecil daripada efek penggantian loss. Efek scheduler yang kecil atau tidak konsisten menunjukkan bahwa faktor ini bukan sumber utama perbedaan pada konfigurasi yang diuji (Willmott & Matsuura, 2005; Kingma & Ba, 2014).

E6 menggabungkan MAE dan ReduceLROnPlateau dan menghasilkan MAE USD 1.667,26. Dibandingkan E3, perubahan MAE E6 adalah perbaikan 32,02%. Perbandingan E6 terhadap E4 dan E5 menunjukkan apakah efek kedua faktor saling memperkuat. Namun, karena semua varian memakai parameter Tier 3 yang sama, hasil ini tidak dapat digunakan untuk mengklaim bahwa kombinasi tertentu akan tetap unggul pada arsitektur atau dataset lain. Interpretasi yang defensible adalah bahwa pada konfigurasi yang diuji, loss MAE dan scheduler menghasilkan perubahan titik yang arah serta besar efeknya dilaporkan pada Tabel 4.3 dan Tabel 4.6; klaim signifikansi tetap mengikuti interval kepercayaan berpasangan, bukan selisih persentase semata (Bouthillier et al., 2021; Greff et al., 2017).

4. Nilai Tambah HPO Penuh: E7 versus E6

E7 dan E6 memakai loss MAE serta scheduler yang sama, sehingga perbedaannya mengisolasi efek HPO penuh. E7 menghasilkan MAE USD 1.687,49, sedangkan E6 menghasilkan USD 1.667,26. selisih MAE E7 − E6 adalah USD +20,23, dengan CI 95% selisih USD +1,22 sampai USD +40,37 yang tidak melewati nol; E6 mencatat MAE lebih rendah daripada E7. HPO penuh tidak menurunkan MAE dibandingkan E6; konfigurasi hasil pencarian justru menghasilkan galat titik yang lebih tinggi. Apa pun arahnya, nilai tambah metodologis tetap terletak pada proses pencarian yang terdokumentasi dan kemampuannya mengungkap kombinasi yang menghasilkan kinerja serupa. Temuan ini sejalan dengan pandangan bahwa evaluasi HPO harus

mempertimbangkan variabilitas dan biaya komputasi, bukan hanya nilai terbaik pada satu trial (Akiba et al., 2019; Feurer & Hutter, 2019).

Model LSTM terbaik pada penelitian ini adalah E6 dengan MAE USD 1.667,26. Peringkat tersebut berbeda dari model usulan E7, sehingga pemilihan model tidak boleh didasarkan pada label 'usulan' atau 'paling kompleks'. Perbedaan ini justru menunjukkan bahwa matriks eksperimen bekerja sebagaimana mestinya: setiap klaim diuji, dan model yang menang ditentukan oleh data, bukan oleh preferensi peneliti. (Bouthillier et al., 2021; Willmott & Matsuura, 2005).

5. Implikasi Teoritis dan Praktis

Secara teoritis, penelitian ini memperkuat pandangan bahwa peramalan harga aset kripto satu langkah ke depan sangat dipengaruhi oleh komponen random walk. Model pembelajaran mendalam dapat menangkap pola non-linier, tetapi pola tersebut belum tentu cukup stabil untuk mengalahkan prediksi naif pada periode uji yang berbeda dari periode latih. Kontribusi metodologis yang lebih kokoh adalah pipeline evaluasi yang memisahkan in-sample dan holdout, memakai scaler per fold, menghitung interval kepercayaan blok, dan melaporkan hasil negatif secara eksplisit (Lim & Zohren, 2021; López de Prado, 2018).

Secara praktis, hasil ini memberi peringatan bagi pengembangan sistem perdagangan algoritmik: akurasi harga yang terlihat tinggi pada data historis tidak otomatis menghasilkan keuntungan setelah biaya transaksi, slippage, dan risiko eksekusi. Model yang tidak mengalahkan persistence pada MAE sebaiknya tidak dipakai sebagai sinyal tunggal untuk keputusan beli atau jual. Penggunaan model perlu disertai manajemen risiko, validasi out-of-time, dan pembandingan dengan strategi naif sebelum diklaim memiliki nilai ekonomi (Gu et al., 2020; Makridakis et al., 2018).

6. Keterbatasan Penelitian

Penelitian ini memiliki beberapa keterbatasan yang harus dibaca bersama hasil. Pertama, data hanya mencakup satu aset, yaitu BTC/USDT, sehingga

temuan belum tentu berlaku untuk aset kripto lain atau pasar tradisional. Kedua, horizon peramalan terbatas pada satu langkah ke depan dan model bersifat univariat, sehingga belum menguji peramalan multi-horizon atau manfaat fitur eksternal seperti sentimen, volume on-chain, dan indikator makroekonomi. Ketiga, evaluasi hanya memakai satu periode holdout sepanjang 439 hari, sehingga hasil sangat bergantung pada rezim pasar yang terjadi pada periode tersebut (Makridakis et al., 2018; Lim & Zohren, 2021).

Keterbatasan keempat adalah belum diperhitungkannya biaya transaksi, bid-ask spread, dan slippage, sehingga angka MAE tidak dapat langsung diterjemahkan menjadi profitabilitas. Kelima, early stopping internal memakai 10% data latih terakhir sebagai validation split; meskipun bersifat kronologis, mekanisme ini masih berpotensi memberi optimism kecil pada pemilihan epoch. Keenam, uji signifikansi bersifat deskriptif dan tidak menggantikan uji formal Diebold-Mariano. Keterbatasan-keterbatasan ini membuka ruang penelitian lanjutan, terutama evaluasi multi-aset dan multi-periode dengan protokol yang sama (Bouthillier et al., 2021; Tashman, 2000).

7. Ringkasan Bab

Bab ini menunjukkan bahwa baseline persistence memiliki MAE USD 1.579,80, sedangkan model LSTM terbaik E6 memiliki MAE USD 1.667,26. Verdict ilmiah berstatus proposed_not_better_than_persistence. Dengan demikian, kontribusi utama penelitian adalah pipeline eksperimen terkontrol, laporan ablasi yang memisahkan loss dan scheduler, serta evaluasi statistik yang jujur tentang batas kemampuan LSTM pada peramalan harga Bitcoin satu langkah ke depan. Bab V merangkum simpulan tersebut dan merumuskan saran penelitian lanjutan.

BAB V
PENUTUP

A. Simpulan

Penelitian ini merancang dan mengevaluasi pipeline optimasi hyperparameter LSTM berbasis Optuna-TPE untuk peramalan harga penutupan Bitcoin satu langkah ke depan. Evaluasi dilakukan dengan matriks terkontrol E0 sampai E7, holdout 439 hari yang tidak dipakai untuk tuning, scaler per fold, purge sebesar lookback, 5 seed, dan moving-block bootstrap. Pertanyaan penelitian dijawab melalui bukti kuantitatif yang dapat ditelusuri ke berkas hasil, bukan melalui klaim bahwa model usulan pasti unggul. Pendekatan ini penting karena peramalan aset kripto rentan menghasilkan kesimpulan yang terlalu optimistis bila baseline naif dan ketidakpastian tidak dilaporkan (Bouthillier et al., 2021; Makridakis et al., 2018).

Simpulan pertama berkaitan dengan kinerja relatif terhadap persistence. Baseline persistence menghasilkan MAE USD 1.579,80 pada holdout, sedangkan model usulan E7 menghasilkan MAE USD 1.687,49. Model LSTM terbaik adalah E6 dengan MAE USD 1.667,26. Verdict ilmiah menyatakan bahwa E7 memiliki MAE lebih tinggi daripada persistence dan CI selisih berpasangan seluruhnya di atas nol, sehingga hasil ini secara statistik lebih buruk. Apabila E7 tidak lebih rendah daripada persistence, maka hasil negatif ini menjadi simpulan utama: pada data dan horizon yang diuji, optimasi hyperparameter belum cukup untuk mengalahkan prediksi naif. Klaim keunggulan tidak boleh dipaksakan hanya karena model lebih kompleks atau proses optimasinya lebih mahal (Willmott & Matsuura, 2005; Lim & Zohren, 2021).

Simpulan kedua berkaitan dengan konfigurasi hasil HPO. E7 memilih lookback 25 hari, 112 unit LSTM, dropout 0,10, learning rate 0,00128, batch size 16, dan 1 layer. Studi menyelesaikan 50 trial dan memilih trial nomor 27. Konfigurasi ini adalah hasil pencarian pada data in-sample, bukan bukti bahwa kombinasi tersebut akan optimal pada aset atau periode lain. Nilai tambah HPO harus dinilai dari perbandingan E7 terhadap E6 yang memakai loss dan scheduler sama, bukan dari besarnya ruang pencarian semata (Akiba et al., 2019; Feurer & Hutter, 2019).

Simpulan ketiga berkaitan dengan ablasi loss dan scheduler. E3 sampai E6 menunjukkan bahwa perubahan fungsi kerugian dan scheduler dapat mengubah MAE, tetapi arah dan besarnya tidak selalu konsisten dengan klaim teoretis. Pada konfigurasi yang diuji, loss MAE dan ReduceLROnPlateau bukan jaminan perbaikan otomatis; keduanya harus dievaluasi bersama variabilitas antar-seed dan interval kepercayaan. Dengan demikian, kontribusi metodologis penelitian ini adalah pemisahan faktor yang jelas dan pelaporan efek yang dapat diaudit, bukan resep hyperparameter yang berlaku umum (Bouthillier et al., 2021; Greff et al., 2017).

Simpulan keempat berkaitan dengan kontribusi metodologis penelitian. Pipeline yang dibangun tetap bernilai karena menyediakan cara mereproduksi eksperimen, memisahkan data tuning dan holdout, menghitung ketidakpastian, dan membandingkan model dengan baseline naif. Temuan bahwa MAE E7 lebih tinggi daripada persistence dengan interval kepercayaan berpasangan yang seluruhnya di atas nol memberi informasi yang jujur bagi praktisi: pada data dan horizon yang diuji, kompleksitas model serta HPO bukan pengganti bukti empiris dan justru menambah galat. Kontribusi tersebut lebih defensible daripada mengklaim keunggulan yang tidak didukung data (Makridakis et al., 2018; López de Prado, 2018).

B. Saran

Penelitian lanjutan disarankan memperluas cakupan data ke beberapa aset kripto dan beberapa periode holdout yang mewakili rezim bull, bear, dan sideways. Evaluasi multi-aset memungkinkan pengujian apakah kegagalan mengalahkan persistence bersifat umum atau hanya terjadi pada BTC/USDT dan periode tertentu. Selain itu, protokol yang sama sebaiknya diterapkan pada data pasar tradisional sebagai pembanding eksternal. Dengan desain seperti ini, klaim generalisasi dapat diuji secara empiris, bukan diasumsikan dari satu run (Lim & Zohren, 2021; Makridakis et al., 2018).

Dari sisi fitur dan arsitektur, penelitian berikutnya dapat menguji model multivariat yang memasukkan volume, indikator on-chain, sentimen berita, dan faktor makroekonomi. Eksperimen juga dapat memperluas horizon dari satu langkah menjadi multi-langkah, serta membandingkan LSTM dengan GRU, Temporal Convolutional Network, atau Transformer dalam protokol tuning yang identik. Perluasan ini harus tetap mempertahankan pemisahan in-sample dan holdout serta scaler per fold agar perbandingan tidak terkontaminasi kebocoran data (Lim & Zohren, 2021; Greff et al., 2017).

Dari sisi evaluasi, penelitian lanjutan perlu menambahkan uji formal seperti Diebold-Mariano, analisis biaya transaksi, bid-ask spread, dan slippage, serta simulasi strategi perdagangan yang realistis. Pelaporan sebaiknya mencakup lebih banyak seed, interval kepercayaan antar-seed, dan analisis sensitivitas terhadap panjang holdout. Dengan demikian, pembaca dapat membedakan peningkatan akurasi statistik dari nilai ekonomi yang nyata. Langkah ini penting agar hasil penelitian tidak berhenti pada angka galat, tetapi memberi panduan yang dapat diuji bagi pengembangan sistem peramalan dan manajemen risiko aset digital (Gu et al., 2020; Tashman, 2000).

DAFTAR PUSTAKA

Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. In Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (pp. 2623–2631). ACM. https://doi.org/10.1145/3292500.3330701

Aldo, D., Firmansyah, M. R., & Amrustian, M. A. (2026). Comparative analysis of hyperparameter optimization methods for LSTM in cryptocurrency price prediction: An application to TRX–USD. Jurnal Teknik Informatika (JUTIF), 7(3), 2340–2349. https://doi.org/10.52436/1.jutif.2026.7.3.5355

Arlot, S., & Celisse, A. (2010). A survey of cross-validation procedures for model selection. Statistics Surveys, 4, 40–79. https://doi.org/10.1214/09-SS054

Aswadi, M., & Ependi, U. (2025). Predicting Bitcoin and Ethereum prices using the Long Short-Term Memory (LSTM) model. Journal of Information

Systems and Informatics, 7(3), 3046–3061. https://doi.org/10.51519/journalisi.v7i3.1228

Bergstra, J., Bardenet, R., Bengio, Y., & Kégl, B. (2011). Algorithms for hyper-parameter optimization. Advances in Neural Information Processing Systems (NeurIPS 2011), 24, 2546–2554. https://papers.nips.cc/paper/2011/hash/86e8f7ab32cfd12577bc2619bc635690-Abstract.html

Binance Developer API. (2024). Binance public market data API documentation: Historical OHLCV kline endpoints. Binance Ltd. https://binance-docs.github.io/apidocs/spot/en/

Boongasame, L., & Songram, P. (2023). Cryptocurrency price forecasting method using long short-term memory with time-varying parameters. Indonesian Journal of Electrical Engineering and Computer Science, 30(1), 435–443. https://doi.org/10.11591/ijeecs.v30.i1.pp435-443

Bouthillier, X., Delaunay, P., Bronzi, M., Trofimov, A., Nichyporuk, B., Szeto, J., Sepah, N., Raff, E., Madan, K., Voleti, V., Kahou, S. E., Michalski, V., Serdyuk, D., Arbel, T., Pal, C., Varoquaux, G., & Vincent, P. (2021). Accounting for variance in machine learning benchmarks. arXiv preprint arXiv:2103.03098. https://doi.org/10.48550/arXiv.2103.03098

Breuel, T. M. (2015). Benchmarking of LSTM networks. arXiv preprint arXiv:1508.02774. https://doi.org/10.48550/arXiv.1508.02774

Creswell, J. W., & Creswell, J. D. (2018). Research design: Qualitative, quantitative, and mixed methods approaches (5th ed.). SAGE Publications.

Fawzi, M. I., Ganesha, T., Anugrah, P. R., Zhahran, M., Abimanyu, F. A., & Bimantoro, H. (2025). Forecasting Bitcoin price prediction with Long Short-Term Memory networks: Implementation and applications using Streamlit. Jurnal Teknik Informatika (JUTIF), 6(5), 2940–2961. https://doi.org/10.52436/1.jutif.2025.6.5.5168

Feurer, M., & Hutter, F. (2019). Hyperparameter optimization. In F. Hutter, L. Kotthoff, & J. Vanschoren (Eds.), Automated machine learning: Methods, systems, challenges (pp. 3–33). Springer. https://doi.org/10.1007/978-3-030-05318-5_1

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep learning. MIT Press. https://www.deeplearningbook.org/

Greff, K., Srivastava, R. K., Koutník, J., Steunebrink, B. R., & Schmidhuber, J. (2017). LSTM: A search space odyssey. IEEE Transactions on Neural

Networks and Learning Systems, 28(10), 2222–2232. https://doi.org/10.1109/TNNLS.2016.2582924

Gu, S., Kelly, B., & Xiu, D. (2020). Empirical asset pricing via machine learning. The Review of Financial Studies, 33(5), 2223–2273. https://doi.org/10.1093/rfs/hhaa009

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. Neural Computation, 9(8), 1735–1780. https://doi.org/10.1162/neco.1997.9.8.1735

Hyndman, R. J., & Athanasopoulos, G. (2018). Forecasting: Principles and practice (2nd ed.). OTexts. https://otexts.com/fpp2/

Kervancı, I. S., & Akay, M. F. (2023). LSTM hyperparameters optimization with Hparam parameters for Bitcoin price prediction. Sakarya University Journal of Computer and Information Sciences, 6(1), 1–9. https://doi.org/10.35377/saucis...1172027

Khumaidi, A., Kusmanto, P., & Hikmah, N. (2024). Optimizing Bitcoin price predictions using Long Short-Term Memory algorithm: A deep learning approach. ILKOM Jurnal Ilmiah, 16(1), 38–45. https://doi.org/10.33096/ilkom.v16i1.1831.38-45

Kingma, D. P., & Ba, J. (2014). Adam: A method for stochastic optimization. arXiv preprint arXiv:1412.6980. https://doi.org/10.48550/arXiv.1412.6980

Lim, B., & Zohren, S. (2021). Time-series forecasting with deep learning: A survey. Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences, 379(2194), 20200209. https://doi.org/10.1098/rsta.2020.0209

López de Prado, M. (2018). Advances in financial machine learning. John Wiley & Sons.

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). The M4 Competition: Results, findings, conclusion and way forward. International Journal of Forecasting, 34(4), 802–808. https://doi.org/10.1016/j.ijforecast.2018.06.001

Optuna Development Team. (2024). Optuna documentation: Tree-structured Parzen Estimator and MedianPruner algorithms. Preferred Networks. https://optuna.readthedocs.io/

Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. Journal of Machine Learning Research, 15(1), 1929–1958. https://jmlr.org/papers/v15/srivastava14a.html

Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: An analysis and review. International Journal of Forecasting, 16(4), 437–450. https://doi.org/10.1016/S0169-2070(00)00065-0

TensorFlow Developers. (2024). TensorFlow: Large-scale machine learning on heterogeneous distributed systems. Google LLC. https://www.tensorflow.org/

Ula, M., Ilhadi, V., & Sidek, Z. M. (2024). Comparing Long Short-Term Memory and Random Forest accuracy for Bitcoin price forecasting. MATRIK: Jurnal Manajemen, Teknik Informatika dan Rekayasa Komputer, 23(2), 259–272. https://doi.org/10.30812/matrik.v23i2.3267

Universitas Islam Nahdlatul Ulama Jepara. (2023). Peraturan Rektor UNISNU Jepara Nomor 57/PR/UNISNU/V/2023 tentang Pedoman Penulisan Skripsi, Tugas Akhir, dan Tesis. UNISNU Jepara.

Wahyuddin, E. P., Caraka, R. E., Kurniawan, R., Caesarendra, W., Gio, P. U., & Pardamean, B. (2025). Improved LSTM hyperparameters alongside sentiment walk-forward validation for time series prediction. Journal of Open Innovation: Technology, Market, and Complexity, 11(1), 100458. https://doi.org/10.1016/j.joitmc.2024.100458

Widad, M. Q., Parlika, R., & Aditiawan, F. P. (2026). Comparative analysis of LSTM and GRU models with hyperparameter optimization for Bitcoin price prediction. Bit-Tech (Binary Digital - Technology), 9(1), 430–440. https://doi.org/10.32877/bt.v9i1.3887

Willmott, C. J., & Matsuura, K. (2005). Advantages of the Mean Absolute Error (MAE) over the Root Mean Square Error (RMSE) in assessing average model performance. Climate Research, 30(1), 79–82. https://doi.org/10.3354/cr030079

LAMPIRAN 1
RINGKASAN KODE PROGRAM PIPELINE KOMPUTASI PYTHON

Berikut merupakan ringkasan modul-modul skrip Python yang dirancang dan dieksekusi dalam lingkungan eksperimen komputasi penelitian, mencakup penarikan data Binance API, pra-pemrosesan bebas kebocoran, pelatihan Tier 1, replikasi manual Tier 2, optimasi Optuna-TPE, matriks eksperimen E0–E7, evaluasi komparatif, dan analisis akhir. Potongan kode bersifat representatif; implementasi lengkap berada pada folder 05_Source_Code/model_experiment.

Modul 01: Penarikan Data Historis Binance API (01_fetch_binance_data.py)

```
import requests, pandas as pd
BASE_URL = 'https://api.binance.com/api/v3/klines'
params = {'symbol': 'BTCUSDT', 'interval': '1d', 'limit': 1000}
# Pagination iteratif: 2.192 observasi harian (2020-01-01 s.d. 2025-12-31)
df = pd.DataFrame(raw_klines, columns=['open_time', 'open', 'high', 'low',
'close', 'volume', ...])
df['close'] = df['close'].astype(float)
df.to_csv('BTCUSDT_daily_2020_2025.csv', index=False)
```

Modul 02: Pra-Pemrosesan & Partisi Data Kronologis (02_preprocessing.py)

```
from sklearn.preprocessing import MinMaxScaler
# Partisi kronologis 80:20 (1.753 in-sample vs 439 holdout)
train_raw = df['close'].iloc[:1753].values.reshape(-1, 1)
test_raw = df['close'].iloc[1753:].values.reshape(-1, 1)
scaler = MinMaxScaler(feature_range=(0, 1))
train_scaled = scaler.fit_transform(train_raw)  # fit hanya pada data latih
test_scaled = scaler.transform(test_raw)
# Pada CV, scaler di-fit ulang pada setiap fold training
```

Modul 03: Pelatihan Model Baseline Default Tier 1 (03_train_baseline_tier1.py)

```
import tensorflow as tf
model = tf.keras.Sequential([
    tf.keras.layers.LSTM(units=50, input_shape=(30, 1)),
    tf.keras.layers.Dropout(0.2),
    tf.keras.layers.Dense(1)
])
model.compile(optimizer=tf.keras.optimizers.Adam(learning_rate=0.001), loss='mse')
model.fit(X_train, y_train, epochs=100, batch_size=32,
          validation_split=0.1, callbacks=[EarlyStopping(patience=12)])
```

Modul 04: Pelatihan Model Replikasi Manual Tuning Tier 2 (04_train_manual_tier2.py)

```
# Parameter Khumaidi dkk. (2024): lookback=60, units=128, dropout=0.20, lr=0.001,
batch=10
model = tf.keras.Sequential([
    tf.keras.layers.LSTM(units=128, input_shape=(60, 1)),
    tf.keras.layers.Dropout(0.20),
    tf.keras.layers.Dense(1)
```

```
])
model.compile(optimizer=tf.keras.optimizers.Adam(learning_rate=0.001), loss='mse')
model.fit(X_train, y_train, epochs=100, batch_size=10, validation_split=0.1)
```

Modul 05: Optimasi Bayesian Tree-structured Parzen Estimator Tier 3 (05_optimize_optuna_tier3.py)

```
import optuna
def objective(trial):
    lookback = trial.suggest_int('lookback', 7, 30)
    units = trial.suggest_int('units', 32, 128)
    dropout = trial.suggest_float('dropout', 0.10, 0.40, step=0.05)
    lr = trial.suggest_float('learning_rate', 5e-4, 2e-3, log=True)
    batch_size = trial.suggest_categorical('batch_size', [16, 32, 64])
    layers = trial.suggest_int('layers', 1, 2)
    # Purged TimeSeriesSplit 5 fold; scaler fit per fold; validasi USD (MAE)
    return cv_mae
study = optuna.create_study(
    direction='minimize',
    sampler=optuna.samplers.TPESampler(seed=42),
    pruner=optuna.pruners.MedianPruner(n_startup_trials=3, n_warmup_steps=1),
)
study.optimize(objective, n_trials=50)
```

Modul 06: Evaluasi Komparatif dan Figur (06_evaluate_and_compare.py)

```
import numpy as np
def compute_metrics(y_true, y_pred):
    rmse = np.sqrt(np.mean((y_true - y_pred) ** 2))
    mae = np.mean(np.abs(y_true - y_pred))
    mape = np.mean(np.abs((y_true - y_pred) / y_true)) * 100
    return {'RMSE': rmse, 'MAE': mae, 'MAPE': mape}
```

Modul 07: Matriks Eksperimen Terkontrol E0–E7 (experiment_matrix.py)

```
EXPERIMENTS = ('E0', 'E1', 'E2', 'E3', 'E4', 'E5', 'E6', 'E7')
# E0 persistence; E1/E2 kontrol; E3-E6 ablasi loss x scheduler;
# E7 HPO penuh. Setiap model dijalankan pada seed 42, 123, 2024, 7, 99.
for seed in (42, 123, 2024, 7, 99):
    run_matrix(experiments=EXPERIMENTS, seed=seed, trials=50)
```

Modul 08: Analisis Akhir dan Publikasi Angka (08_analyze_results.py)

```
summary = build_summary(run_dir)
# Metrik holdout, CI moving-block bootstrap, variabilitas antar-seed,
# analisis residual/rezim, dan verdict ilmiah ditulis ke satu berkas.
write_json(run_dir / 'summary_final.json', summary)
if publish:
    write_json(RESULTS_ROOT / 'summary_final.json', summary)
```

LAMPIRAN 2
SAMPEL DATA HISTORIS TRANSAKSI HARIAN BINANCE BTC/USDT (2020–2025)

Berikut merupakan cuplikan sampel data historis transaksi harian pasangan BTC/USDT yang dihimpun dari Binance Public Market Data API sebanyak 2.192 hari. Tabel di bawah menampilkan 15 observasi awal periode Januari 2020 dan 15 observasi akhir periode Desember 2025 dengan atribut Open, High, Low, Close (USD), serta Volume perdagangan harian (BTC).

No.	Tanggal	Open (USD)	High (USD)	Low (USD)	Close (USD)
1	2020-01-01	7,195.24	7,255.00	7,175.15	7,200.85
2	2020-01-02	7,200.77	7,212.50	6,924.74	6,965.71
3	2020-01-03	6,965.49	7,405.00	6,871.04	7,344.96
4	2020-01-04	7,345.00	7,404.00	7,272.21	7,354.11
5	2020-01-05	7,354.19	7,495.00	7,318.00	7,358.75
6	2020-01-06	7,357.64	7,795.34	7,346.76	7,758.00
7	2020-01-07	7,758.90	8,207.68	7,723.71	8,145.28
8	2020-01-08	8,145.92	8,455.00	7,870.00	8,055.98
9	2020-01-09	8,054.72	8,055.96	7,750.00	7,817.76
10	2020-01-10	7,817.74	8,199.00	7,672.00	8,197.02
11	2020-01-11	8,198.86	8,286.34	8,003.16	8,020.01
12	2020-01-12	8,020.01	8,197.00	7,960.00	8,184.98
	...				...
2181	2025-12-20	88,136.95	88,573.07	87,795.76	88,360.90
2182	2025-12-21	88,360.91	89,081.77	87,600.04	88,658.86
2183	2025-12-22	88,658.87	90,588.23	87,900.00	88,620.79
2184	2025-12-23	88,620.79	88,940.00	86,601.90	87,486.00
2185	2025-12-24	87,486.00	88,049.89	86,420.00	87,669.45
2186	2025-12-25	87,669.44	88,592.74	86,934.72	87,225.27
2187	2025-12-26	87,225.27	89,567.75	86,655.08	87,369.56
2188	2025-12-27	87,369.56	87,984.00	87,253.05	87,877.01

2189	2025-12-28	87,877.00	88,088.75	87,435.00	87,952.71
2190	2025-12-29	87,952.71	90,406.08	86,806.50	87,237.13
2191	2025-12-30	87,237.13	89,400.00	86,845.66	88,485.49
2192	2025-12-31	88,485.50	89,200.00	87,250.00	87,648.22

LAMPIRAN 3
LOG RIWAYAT 50 PERCOBAAN OPTIMASI BAYESIAN OPTUNA-TPE

Tabel berikut merangkum seluruh riwayat 50 percobaan (trials) yang dieksekusi oleh algoritma Optuna berbasis Tree-structured Parzen Estimator (TPE) dan mekanisme pemangkasan MedianPruner. Parameter yang dicatat meliputi nomor trial, lookback window, units, dropout rate, learning rate, batch size, jumlah layer, nilai objektif validasi silang berpurge dalam USD, serta status akhir trial. Baris yang disorot adalah trial terbaik yang dipilih berdasarkan nilai objektif terkecil pada data in-sample.

Trial	Lookback	Units	Dropout	Learning Rate	Batch / Layer	Nilai Objektif (USD)	Status
0	15	124	0.35	0.0011	16 / 2	3584.386732	COMPLETE
1	21	100	0.10	0.0019	16 / 1	1341.532472	COMPLETE
2	14	82	0.25	0.0007	16 / 1	2860.167325	COMPLETE
3	17	108	0.15	0.0010	64 / 1	840.584607	PRUNED
4	8	124	0.40	0.0015	64 / 1	689.893305	PRUNED
5	9	80	0.10	0.0018	32 / 2	965.864370	PRUNED
6	20	49	0.40	0.0015	16 / 2	846.610043	PRUNED
7	9	51	0.10	0.0008	64 / 1	2077.217520	PRUNED
8	13	84	0.10	0.0015	32 / 1	2141.828014	COMPLETE
9	7	111	0.30	0.0014	16 / 1	751.940754	PRUNED
10	26	64	0.25	0.0011	16 / 1	2097.637347	PRUNED
11	21	109	0.15	0.0017	16 / 1	1385.736059	COMPLETE
12	23	123	0.25	0.0018	16 / 1	1461.757199	COMPLETE
13	20	100	0.10	0.0018	16 / 1	1117.564752	COMPLETE
14	30	96	0.15	0.0016	16 / 1	720.291013	PRUNED
15	22	109	0.10	0.0015	16 / 2	790.771828	PRUNED
16	20	71	0.20	0.0016	32 / 1	792.570661	PRUNED
17	27	80	0.10	0.0013	64 / 1	1817.348874	PRUNED
18	14	91	0.20	0.0017	16 / 1	1709.952273	PRUNED

19	26	118	0.10	0.0020	16 / 2	769.345220	PRUNED
20	22	126	0.10	0.0010	16 / 1	689.128170	PRUNED
21	20	96	0.10	0.0017	16 / 1	1155.859860	COMPLETE
22	23	87	0.10	0.0019	16 / 1	1451.724561	COMPLETE
23	17	110	0.20	0.0013	16 / 1	1473.719703	PRUNED
24	18	95	0.10	0.0013	16 / 1	693.400190	PRUNED
25	18	89	0.15	0.0019	16 / 1	1524.395073	PRUNED
26	14	85	0.10	0.0020	16 / 1	836.750522	PRUNED
27	**25**	**112**	**0.10**	**0.0013**	**16 / 1**	**1092.794350**	**COMPLETE**
28	14	118	0.15	0.0016	16 / 1	1500.155637	PRUNED
29	26	107	0.10	0.0011	16 / 1	1714.241978	PRUNED
30	23	120	0.15	0.0014	16 / 1	1696.800962	PRUNED
31	20	106	0.10	0.0019	16 / 1	1469.361163	PRUNED
32	23	94	0.10	0.0013	16 / 1	1512.312314	PRUNED
33	16	113	0.15	0.0019	16 / 1	1397.775547	COMPLETE
34	30	96	0.10	0.0012	16 / 1	1476.570897	PRUNED
35	26	101	0.15	0.0019	16 / 1	1522.226193	PRUNED
36	19	99	0.10	0.0015	16 / 1	1438.759450	PRUNED
37	26	116	0.10	0.0015	16 / 1	1575.901676	PRUNED
38	20	107	0.15	0.0011	16 / 1	1828.003870	PRUNED
39	18	120	0.10	0.0017	16 / 1	1120.507022	COMPLETE
40	19	121	0.15	0.0016	16 / 1	1459.859282	PRUNED
41	25	101	0.10	0.0017	16 / 1	654.709652	PRUNED
42	14	116	0.10	0.0012	16 / 1	1431.917953	PRUNED
43	24	109	0.15	0.0012	16 / 1	2042.028337	PRUNED
44	28	115	0.10	0.0013	16 / 1	1455.894790	PRUNED
45	17	104	0.10	0.0017	16 / 1	1428.477266	PRUNED
46	23	109	0.15	0.0019	16 / 1	2203.732409	PRUNED
47	21	95	0.10	0.0018	16 / 1	736.277443	PRUNED
48	22	111	0.10	0.0015	16 / 1	1193.262114	COMPLETE
49	22	81	0.10	0.0014	16 / 1	1484.245467	PRUNED